

## 1.1.1 - Linear Algebra

$$1) A = \begin{bmatrix} 1 & 1 & 0 \\ 1 & -1 & 2 \\ 0 & 2 & 1 \end{bmatrix}$$

$$A^T A = \begin{bmatrix} 1 & 1 & 0 \\ 1 & -1 & 2 \\ 0 & 2 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 & 0 \\ 1 & -1 & 2 \\ 0 & 2 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & -2 \\ 2 & -2 & 4 \end{bmatrix}$$

0 - δ הינה מטרית אוניברסיטאית כי  $A^T A$  הוא מטרית ריבועית ו- $\lambda$  נסיעה

$$|A^T A - I\lambda| = \left| \begin{bmatrix} 2-\lambda & 0 & 2 \\ 0 & 2-\lambda & -2 \\ 2 & -2 & 4-\lambda \end{bmatrix} \right| = 0$$

הנורמליזציה של מטרית ריבועית

$$2 \cdot x ((2-x) \cdot (4-x) - 2 \cdot 2) - 0 \cdot (\dots) + 2 ((0 \cdot -2) - (2 \cdot (2-x))) = 0$$

$$= 2 - \lambda (8 - 2x - 4x + x^2 - 4) + 2 (-4 + x) = 0$$

$$= (2 - \lambda)(x^2 - 6x + 4) - 4(2 - \lambda) = 0$$

$$= (x^2 - 6x)(2 - \lambda) = 0$$

∴

$$\boxed{\lambda_1 = 2}$$

הנורמליזציה של מטרית ריבועית

$$x^2 - 6x = 0$$

=)

$$\sigma_1 = \sqrt{2}$$

$$\sigma_2 = \sqrt{6}$$

$$\sigma_3 = 0$$

$$\boxed{\lambda_2 = 0}$$

$$x(x-6) = 0$$

כטב פונקציית גזען רגילה וריבויים:

$$\lambda_1 = 2$$

$$\begin{bmatrix} 2-2 & 0 & 2 \\ 0 & 2-2 & -2 \\ 2 & -2 & 4-2 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 2 \\ 0 & 0 & -2 \\ 2 & -2 & 2 \end{bmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} \Rightarrow \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} \cdot \sqrt{2}$$

כטב פונקציית גזען רגילה וריבויים

$$\lambda_2 = 6$$

$$\begin{bmatrix} 2-6 & 0 & 2 \\ 0 & 2-6 & -2 \\ 2 & -2 & 4-6 \end{bmatrix} = \begin{bmatrix} -4 & 0 & 2 \\ 0 & -4 & -2 \\ 2 & -2 & -2 \end{bmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} \Rightarrow \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} \cdot \sqrt{6}$$

כטב פונקציית גזען רגילה וריבויים

$$-4x_1 + 2x_3 = 0 \Rightarrow x_3 = 2x_1$$

$$-4x_2 - 2x_3 = 0 \Rightarrow x_3 = -2x_2$$

$$2x_1 - 2x_2 - 2x_3 = 0 \Rightarrow$$

$$x_3 = 0$$

$$\begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & -2 \\ 2 & -2 & 4 \end{bmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{bmatrix} 1 \\ -1 \\ -1 \end{bmatrix} \cdot \sqrt{3}$$

כטב פונקציית גזען רגילה וריבויים

$$2x_1 + 2x_3 = 0 \Rightarrow x_3 = -x_1$$

$$2x_2 - 2x_3 = 0 \Rightarrow x_3 = x_2$$

$$V = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{3}} \\ 0 & \frac{2}{\sqrt{6}} & -\frac{1}{\sqrt{3}} \end{bmatrix}$$

$$\sum = \begin{bmatrix} \sqrt{2} & 0 & 0 \\ 0 & \sqrt{6} & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

כטב פונקציית גזען רגילה וריבויים

: U וילוקס פונקציית

$$AV = V \sum$$

טב פונקציית גזען רגילה וריבויים

$$\sum_{i=1}^n \underline{v_i} = A \vee \sum_{i=1}^n \underline{u_i} = U$$

$$\begin{bmatrix} 1 & 1 & 0 \\ 1 & -1 & 2 \end{bmatrix} \xrightarrow{\text{Row Operations}} \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{3}} \\ 0 & \frac{2}{\sqrt{6}} & -\frac{1}{\sqrt{3}} \end{bmatrix} \xrightarrow{\text{Row Operations}} \begin{bmatrix} \sqrt{2} & 0 & 0 \\ 0 & \sqrt{6} & 0 \\ 0 & 0 & 0 \end{bmatrix} = U$$

$$\begin{bmatrix} \frac{1}{\sqrt{2}} + \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{6}} - \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{3}} - \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{2}} - \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{6}} + \frac{1}{\sqrt{6}} + \frac{4}{\sqrt{6}} & \frac{1}{\sqrt{3}} + \frac{1}{\sqrt{3}} - \frac{2}{\sqrt{3}} \\ 0 & 0 & 0 \end{bmatrix} \xrightarrow{\text{Row Operations}} \begin{bmatrix} \sqrt{2} & 0 & 0 \\ 0 & \sqrt{6} & 0 \\ 0 & 0 & 0 \end{bmatrix} = U$$

$$= \begin{bmatrix} \sqrt{2} & 0 & 0 \\ 0 & \sqrt{6} & 0 \\ 0 & 0 & 0 \end{bmatrix} \xrightarrow{\text{Row Operations}} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix} = I$$

$$\boxed{\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix} = U}$$

$$2) v \in \mathbb{R}^n, u \in \mathbb{R}^m$$

:  $\mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}^{n \times m}$

$$A = \begin{pmatrix} v_1 \\ \vdots \\ v_n \end{pmatrix} \cdot (u_1, \dots, u_m) = \begin{bmatrix} v_1 u_1 & \dots & v_1 u_m \\ \vdots & & \vdots \\ v_n u_1 & \dots & v_n u_m \end{bmatrix} = \boxed{\begin{bmatrix} v \otimes u \end{bmatrix}_{ij}} = v_i \cdot u_j$$

$$\begin{pmatrix} v_1 u_1 \\ \vdots \\ v_n u_1 \end{pmatrix} \quad \begin{pmatrix} v_1 u_2 \\ \vdots \\ v_n u_2 \end{pmatrix} \quad \dots$$

:  $\mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}^{n \times m}$

רוכסן ור' מילר כרך ג' סעיפים 1-5:

$u_1 \begin{pmatrix} v_1 \\ \vdots \\ v_n \end{pmatrix}$   $u_r \begin{pmatrix} v_1 \\ \vdots \\ v_n \end{pmatrix}$   $u_3 \begin{pmatrix} v_1 \\ \vdots \\ v_n \end{pmatrix}$

בנוסף לORTHOGONALITY של  $u_i$  ו- $u_j$  (ב- $\mathbb{R}^n$ ) נקבע ש- $u_i$  מוגדר כORTHOGONAL ל- $v_i$ .

(ORTHOGONALITY של  $u_i$  ו- $u_j$  מוגדר ב- $\mathbb{R}^n$  כORTHOGONALITY של  $v_i$  ו- $v_j$ )

• דוגמאות  $\text{rank}(A) = 1$  | 181

3)  $x = \sum_{i=1}^n a_i u_i \in \mathbb{R}^n$   $a_i \in \mathbb{R}, (u_1, \dots, u_n) \in \mathbb{R}^n$

$\langle x, u_j \rangle = \left\langle \sum_{i=1}^n a_i u_i, u_j \right\rangle = \sum_{i=1}^n a_i \langle u_i, u_j \rangle$

אם  $i \neq j$   $\langle u_i, u_j \rangle = 0$  (ORTHOGONALITY)

אם  $i = j$   $\langle u_i, u_j \rangle = 1$  (ORTHOGONALITY)

$\therefore \sum_{i=1}^n a_i \langle u_i, u_j \rangle = a_j$

$a_j = \langle x, u_j \rangle$   $\forall j$

4) a)  $x = \begin{pmatrix} 3 \\ -4 \\ 1 \\ -2 \end{pmatrix}$ ,

•  $\|x\|_1 = 3 + 4 + 1 + 2 = 10$

•  $\|x\|_2 = \sqrt{3^2 + 4^2 + 1^2 + 2^2} = \sqrt{9 + 16 + 1 + 4} = \sqrt{30}$

$$\|x\|_\infty = y$$

פונקציית היקף גראם הינה כפולה, כלומר שטח המושג מוקף בדקה צייר,  $x$

בנוסף לערך נ-ה יסוד שטח המושג מוקף בדקה צייר, מינימום ומקסימום


$$y - g \geq 1 \text{ ריבוע כפונקציית מינימום מ-} y \approx 2.162$$

b)  $\ell_1$ :

$$\|x\|_1 = 1$$

$\Downarrow$

$$x = (x, y) \Rightarrow |x| + |y| = 1$$



$$x + y = 1 \Rightarrow y = 1 - x$$

$$-x + y = 1 \Rightarrow y = 1 + x$$

$$x - y = 1 \Rightarrow y = x - 1$$

$$-x - y = 1 \Rightarrow y = -x - 1$$

$\ell_2$ :

$$\|x\|_2 = 1$$

$$\sqrt{x^2 + y^2} = 1$$


למוניטור

נו-ה-ה-ה

ה-ה-ה

א-ה-ה-ה

ה-ה-ה



$\ell_\infty$ :

$$\|x\|_\infty = 1$$

↓

$$\max\{x, y\} = 1$$

: גיאור

$$y=1$$

$$x=-1$$


$$x=1$$

$$x \geq 1, -1 \leq y \leq 1$$

$$\left| \begin{matrix} 1 & 0 \\ 0 & 1 \end{matrix} \right|$$

$$y \leq -1$$

$$y \geq 1, -1 \leq x \leq 1$$



השאלה מבקשת לנו למצוא את היקף ושטח המרחב  $|x| + |y| \leq 1$  ב**ריבוע**  $-1 \leq x \leq 1, -1 \leq y \leq 1$ :

ל1: נשים  $x = 0$  ו $y = 0$ . אז  $|x| + |y| = 0$ . אם  $x > 0$  ו $y > 0$ , אז  $|x| + |y| = x + y$ . אם  $x < 0$  ו $y < 0$ , אז  $|x| + |y| = -x - y$ .

כיוון ש**היקף** הוא סכום כל גודלי רוחב, אז  $|x| + |y| = 0$  ב**היקף**  $|x| + |y| \leq 1$ . בהיקף  $|x| + |y| \leq 1$  יש  $4 \times \frac{1}{2} \times 1 \times 1 = 2$  יחידות רוחב.

ל2: סיכום:  $\int_{-1}^1 \int_{-1-x}^{1-x} dy dx = 2 \int_0^1 (1-x) dx = 2 \left[ x - \frac{x^2}{2} \right]_0^1 = 2 \left( 1 - \frac{1}{2} \right) = 1$ .

. סיכום

או, גודלה

היקף  $|x| + |y| \leq 1$  הוא סכום של  $4 \times \frac{1}{2} \times 1 \times 1 = 2$  יחידות רוחב.

ל3: ריבוע:

# 1.1.2 - Multivariate Calculus

b)  $h(\sigma) = \frac{1}{2} \|f(\sigma) - y\|^2, \sigma \in \mathbb{R}^d, f: \mathbb{R}^d \rightarrow \mathbb{R}^d$

הנתקה ר'ה

$$\nabla h(\sigma) = J_f(\sigma)^T \cdot \nabla h(f(\sigma))$$

↓

$$\nabla_x \|g(x)\|^2 = 2g(x)^T \cdot \nabla g(x); \text{הוכחה דומה}$$

:|ס

$$\nabla h(\sigma) = J_f(\sigma)^T \cdot \nabla h(f(\sigma)) = J_f(\sigma)^T \cdot 2 \cdot \frac{1}{2} \cdot (f(\sigma) - y)$$

$$= J_f(\sigma)^T \cdot (f(\sigma) - y)$$

c)  $S(x)_j = \frac{e^{x_j}}{\sum_{k=1}^K e^{x_k}}$

$$S: \mathbb{R}^K \rightarrow [0, 1]^K$$

: נבנה

$$J_S = \begin{bmatrix} \frac{\partial S_1(x)}{\partial x_1} & \dots & \dots & \frac{\partial S_1(x)}{\partial x_K} \\ \vdots & & & \vdots \\ \frac{\partial S_K(x)}{\partial x_1} & \dots & \dots & \frac{\partial S_K(x)}{\partial x_K} \end{bmatrix}$$

הנתקה ר'ה,  $i=j$  נגדי נסיבות ור'ה,  $\frac{\partial S_i}{\partial x_j} = S_i(1 - S_i)$

$$\frac{\partial S_i}{\partial x_j} = \frac{\partial}{\partial x_j} \left( \frac{e^{x_j}}{\sum_k e^{x_k}} \right) = \frac{e^{x_j} \sum_k e^{x_k} - e^{x_i} \cdot e^{x_j}}{(\sum_k e^{x_k})^2} = \frac{e^{x_j}}{\sum_k e^{x_k}} \cdot \frac{\sum_k e^{x_k} - e^{x_i}}{\sum_k e^{x_k}} = S_i(1 - S_i)$$

הנתקה ר'ה,  $i \neq j$  נגדי נסיבות ור'ה,  $\frac{\partial S_i}{\partial x_j} = 0$

$$\frac{\partial s_i}{\partial x_j} = \frac{\partial}{\partial x_j} \left( \frac{e^{x_i}}{\sum_k e^{x_k}} \right) \stackrel{?}{=} \frac{0 \cdot \sum_k e^{x_k} - e^{x_i} \cdot e^{x_i}}{\left( \sum_k e^{x_k} \right)^2} = \frac{-e^{x_i} \cdot e^{x_i}}{\left( \sum_k e^{x_k} \right)^2}$$

$$= \frac{-e^{x_i}}{\sum_k e^{x_k}} \cdot \frac{e^{x_i}}{\sum_k e^{x_k}} = -s_j \cdot s_i$$

108 | מילויים | נסח' כדו:

$$J_{S_i}^{(x)} = \begin{bmatrix} s_1(1-s_1) - s_1 \cdot s_2 & \dots & -s_1 \cdot s_K \\ -s_2 \cdot s_1 & s_2(1-s_2) & -s_2 \cdot s_K \\ \vdots & \ddots & \vdots \\ -s_K \cdot s_1 & \dots & s_K(1-s_K) \end{bmatrix}$$

## 1.2: Linear Regression:

$$X \in \mathbb{R}^{m \times d}, Y \in \mathbb{R}^m$$

מתקדם יריעות  
הנורמליזציה

5) a)  $\underline{=}$

הנורמליזציה  
 $X^T \cdot v$

$$v \in \ker(X) \Rightarrow X \cdot v = 0 \Rightarrow X^T \cdot X \cdot v = X^T \cdot 0 = 0 \Rightarrow v \in \ker(X^T \cdot X)$$

$$v \in \ker(X^T \cdot X) \Rightarrow X^T \cdot X \cdot v = 0 \Rightarrow v^T \cdot X^T \cdot X \cdot v = v^T \cdot 0 = 0 \Rightarrow \|Xv\|^2 = 0$$

אנו מודדים

$$\Rightarrow Xv = 0 \Rightarrow v \in \ker(X)$$



b)  $A \in \mathbb{R}^{m \times m}$   
 $v \in \mathbb{R}^m$

$$\forall v \in \text{Im}(A^T) \Rightarrow A^T w = v$$

$$\text{ker}(A)^{\perp} = \{v \mid v^T w = 0, \forall w \in \text{ker}(A)\}, Aw = 0$$

$A^T$  גורם ל- $v$  ב- $\text{Im}(A)$ ,  $w \in \text{ker}(A)$ ,  $w^T A^T = 0$

$\text{Im}(A^T) = \text{ker}(A)^{\perp}$  מכיוון ש- $w$  מושך את כל ה- $v$  ב- $\text{Im}(A^T)$

c)  $x \in \text{ker}(x^T) \iff x^T x = 0$  מכיוון ש- $x^T x = 0$  אם ורק אם  $x = 0$

$$x^T v = 0$$

$$x^T w = y \iff y \in \text{Im}(x^T) \iff y \in \text{ker}(x)^{\perp} \iff y \perp \text{ker}(x)$$

$\downarrow$

לפיכך  $y \in \text{Im}(x^T) \iff x^T y = 0$  אם ורק אם  $y \in \text{ker}(x)$ .

d)  $x^T x w = x^T y$

אם  $x^T x = 0$ ,  $\text{ker}(x^T x) = \text{ker}(x)$  :  
 $\text{ker}(x) = \{0\}$

. $x \in \text{ker}(x^T x) \iff x^T x = 0$

בנוסף

לפיכך  $x^T x = 0 \iff x^T x w = x^T y$

פירושו  $x^T x w = x^T y \iff x^T (w - y) = 0$

## 1.2.2:

$$1) x^+ y = \sqrt{\sum}^+ U^T y \quad (*)$$

$$2) x^T x = (U \Sigma V^T)^T (U \Sigma V^T) = \sqrt{\sum}^T U^T U \Sigma V^T$$

$$= \sqrt{\sum}^2 V^T \Rightarrow [x^T x]^{-1} = \sqrt{(\Sigma^2)^{-1}} V^T$$

surrounding  $\Sigma$

surrounding  $V$

↓

$$[x^T x]^{-1} x^T y = \sqrt{(\Sigma^2)^{-1}} V^T x^T y = \sqrt{(\Sigma^2)^{-1}} V^T \sqrt{\sum} U^T y$$

$$= \sqrt{(\Sigma^2)^{-1}} \sum U^T y \stackrel{+ \text{ mean}}{\Downarrow} \sqrt{\sum}^+ U^T y = x^+ y$$

surrounding  $\Sigma$

surrounding  $V$

□

## Practical part answers:


### Linear Regression:

(3) האפיז'רים שבחרתי להוריד הם ID, DATE, YR\_BUILT, YR\_RENOVATED לאחר ID הוא שדה שרירותי ללא כל משמעות מתמטית על מחיר הבית וכן לגביו DATE. לגבי YR\_RENOVATED, YR\_BUILT ההפרש מהשנה הנוכחית לשנה הנוכחית מאוחר ולדעתו אלו נתונים שייתר נוח להסתכל עליהם ולהסביר מסקנות (למשל בתים באזור גיל 30 שווים פחות זהה נתון שלא קופץ לעין בaczat קלות לפי שנה בנייה) מאשר הספציפיות שבה הבית נבנה \ שופץ.


ב) הוסיף חמישה פיצ'רים חדשים: **גיל בית, שנים מאז שיפוץ** – נתונים יותר נוחים לניתוח לדעתו מאשר הפיצ'רים המקוריים המקוריים להם. בנוסף הוסיף **הפרש בין גודל מגורים ממוצע 15 קרובים, הפרש בין גודל מגרש לממוצע 15 קרובים**. אלה נתונים שלדעתו יתנו זווית יותר עניינית על הנתונים- איך ההפרש מהגודל הממוצע של 15 השכנים הקרובים משפיע על המחיר.

ג) לגבי נתונים INVALID/MISSING פשוט מחקתי את כל השורה מהנתונים כי לא ניתן לסמן עליה לדעתו.


4) גרפף 1- שטח אזור בניי למגורים, ניתן לראות שפיצ'ר זה מאוד רלוונטי למחיר, ציון קוורציט הפירסון שלו הוא 0.7 מה שמעיד על קשרalink לינארי גבוה ונitinן לראות גם בגרף את מגמת העלייה במחיר בהתאם לעלייה בשטח הבניי למגורים. ככלمر פיצ'ר זה מאוד רלוונטי למודל.



ग्रף 2- הפרש בין שטח הבית הכלול לבין שטח הבית הכלול של 15 השכנים הקרובים ביותר אליו. זהו אחד הפיצ'רים שאני הוסיף ולחפות עתי ניתן לראות שהקשר הלינארי מאוד נמוך ככלומר אין השפעה של אמיתית על מחיר הבית של ההפרש בין הנזונים הללו. ניתן לראות זאת כי ציון הפירוטון קרוב מאוד ל 0 וגם בגרף עצמו ניתן לראות שאין קשר לינארי אמיתי ולכן נראה שאנשים לא מאוד מושפעים מהשווות שטח ביתם לשטח של בית שכנים עד כדי עליית מחירים.



(6)




ניתן לראות שMSE נע בין  $4.2 \times 10^9$  ל- $4.5 \times 10^9$  ומאחר והוא מחושב בצורה ריבועית הuzzo הוא בעצם באזור 200,000 שזה נשמע סביר בהתאם למחירי בתים( מיליון ).


בנוסף ניתן לראות שיש קורלציה בין אחוז הדגימה לירידה בMSE הכללי, כלומר המודל משתפר ככל שהוא מקבל דוגימה יותר גדולה מהנתונים, בהתחלה השינויים חדים אך מאוחר ה-50 אחוז דגימה MSE כמעט ולא משתנה ככלומר אין לכמות הנתונים שגדלה משמעותית בהקטנת LOSS. לגבי ה- $\text{loss} - 2\text{-}\text{std}$  Confidence interval of mean( $\text{loss}$ ) ניתן לראות שבתחילה הוא בטוחה רחבה מאוד מהMSE עצמו אך ככל שהדגם עולה הטוחה שלו מctratzם והוא נהיה כמעט זהה ל-MSE האמיטי ככלומר טוחה LOSS של דגם מתקרב ל-MSE הממוצע שקיבלנו ככל שאחוז הדגימות עולה, זה מעיד על מודל שמשתperf ככל שהוא לומד יותר.

### Polynomial Fitting:

(3)




לפי צורת הגרף ניתן לראות שהgraf ד' מתאים לכל פולינום מדרגה אי זוגית בשל צורתו וכן אשר שעלה שהדרגה המתאימה ביותר היא 3 או 5.



בהתאם לגרף נשים לב שהשינויים של טמפרטורה יומיית באותו חודש משתנה בין החודשים וכן נשער שמודל החיזוי יעבוד בצורה הטובה ביותר על חודשים בהם השונות הזאת היא הקטנה ביותר (יולי, אוגוסט) לעומת חודשים בהם השונות היא גדולה (מרץ אפריל) וכן המודל יצילח במידה שונה לכל חודש.

(4)




בהתאם לגרף ניתן לראות שישראל, ירדן והולנד נצמדות לאותה תבנית אך הולנד עם טמפרטורות כליליות יותר נמצאות לאורך כל השנה. לעומת זאת דרום אפריקה נצמדת לתבנית הפוכה לומר דבר שמסתדר עם העונות ההפוכות בשל הימצאותו בחצי כדור הארץ הדרומי. מפאת תוצאות אלה נסיק שהמודל שיתאים לישראל יתאים כנראה בזרה המקסימלית גם לירדן בשל הדמיון המקסימלי בין הגрафים של שתי המדינות.

(5)

```


k=1, loss=21.320242021509923
k=2, loss=6.825831621422252
k=3, loss=3.171923340889096
k=4, loss=2.7135381423401213
k=5, loss=2.619784398159097
k=6, loss=7.454277989377751
k=7, loss=17.273324151668007
k=8, loss=35.00129019730737
k=9, loss=35.000859274784695
k=10, loss=35.00079890448881

```



ניתן לראות לפי התוצאות שהערך המינימלי של LOSS מגיע כאשר  $k=5$  כלומר פולינום מדרגה 5 הוא אופטימלי לזרע את LOSS ניתן בנוסף לראות שם 3 ו 4 נתונים ערכים טובים שווים ליצור מודל פולינומי אך לא כמו 5.

(6)



ניתן לראות שבהתאם להשערהנו בשאלת LOSS הנמור ביותר לא האופטימלי(5) ירדן היא המדינה שהמודל שפיתחנו הכי מתאים לה כי בה ערך LOSS הנמור ביותר שזו השאייפה במודל. מה שכנן מפתיע הוא שדרומ אפריקה במקום השני על אף שבשאלת 4 צפינו שהולנד תהיה במקום השני כנראה בשל השוני הגדול בטמפרטורות הממציאות.