

Theoretical Part:

1.1) Hard & Soft - SVM:

המגדיר הhard SVM בmathematical מושג:

$$\arg \min_{(w,b)} \|w\|^2 \quad \text{s.t.} \quad \forall i: y_i(w^T x_i + b) \geq 1$$

בפונקציית פולינומיאלית Q, A מוגדרת:

$$\arg \min_{V} \frac{1}{2} V^T Q V + \alpha^T V \quad \text{s.t.} \quad AV \leq d$$

$$V := \begin{bmatrix} w \\ b \end{bmatrix}$$

$$\|V\|^2 = V^T I V$$

$$\arg \min \|w\|^2 = \arg \min W^T I W = \frac{1}{2} V^T Q V + \alpha^T V$$

המשתנה V מוגדר כ $V = \begin{bmatrix} w \\ b \end{bmatrix}$ ו- w מוגדר כ $w^T Q V$.

$$w^T Q V = \|w\|^2$$

המשתנה α מוגדר כ $\alpha^T V$.

$$\arg \min \|w\|^2 = \arg \min \frac{1}{2} V^T Q V + \alpha^T V$$

\uparrow
המשתנה V

המשתנה Q

המשתנה α

כונס מנגנון פירוט ב-318.k וק' 2018 נובמבר (בנוסף ל-2018)

$$\forall i: y_i (\langle w, x_i \rangle + b) \geq 1$$

$$\Leftrightarrow \forall i: y_i x_i^T w + y_i b \geq 1$$

$$\Leftrightarrow \forall i: -y_i x_i^T w - y_i b \leq -1 \quad (\Leftarrow) \quad -y_i (x_i^T w + b) \leq -1$$

כדי שפונקציית הבדקה תהיה גלומה נשים את ה- y_i ב- A_i .

$$-y_i (x_i^T w + b) \Leftrightarrow -y_i [x_i^T \ 1] \begin{bmatrix} w \\ b \end{bmatrix} = A_i \vee \leq -1$$

$$A_i = -y_i \cdot [x_i^T \ 1]$$

כגון ב- \mathbb{R}^{d+1} אוסף A יתנו A_i ב-

$$A = \begin{bmatrix} -y_1 \cdot [x_1^T \ 1] \\ -y_2 \cdot [x_2^T \ 1] \\ \vdots \\ -y_{d+1} \cdot [x_{d+1}^T \ 1] \end{bmatrix} \in \mathbb{R}^{(d+1) \times (d+1)}$$

$$J = \begin{pmatrix} -1 \\ \vdots \\ -1 \end{pmatrix} \in \mathbb{R}^{d+1}$$

ב- \mathbb{R}^{d+1} כריסטיאן הילמן מ- IAS מ- IAS מ- IAS מ- IAS

1.2) PAC Learnability:

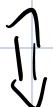
1) גjm סgn מינ' co Sm, X סgn מינ' co D. ה' ג'ג
 $\exists \text{ s.t. } x \subseteq X \text{ s.t. } \delta^x, x \text{ סgn מינ' co D}$
 $P_D[S_m \cap X = \emptyset] \leq e^{-m\varepsilon} \text{ proof: } P_D[x \in X] > \varepsilon$

ליכו:

$$P_D[x \in X] > \varepsilon \Rightarrow P_D[x \notin X] < 1 - \varepsilon \quad \text{⊗}$$

: מינ' co D מינ' co S

$$P_D[\forall x_i \in S_m \notin X] = \prod_{i=1}^m P_D[x_i \notin X] \leq (1 - \varepsilon)^m \leq e^{-m\varepsilon}$$



done

$$P[S_m \cap X = \emptyset]$$

ג'ג מינ' co S מינ' co D

b) ג'ג מינ' co S מינ' co D מינ' co D מינ' co S מינ' co D

$$L_{D,f}(\hat{f}_S, S) = 0 \quad \text{מינ' co S מינ' co D מינ' co A}$$

$$P_D[L_{D,f}(\hat{f}_S) > \varepsilon] \quad \text{מינ' co D מינ' co S}$$

מינ' co S מינ' co D מינ' co A מינ' co S מינ' co D מינ' co A

\hat{f}_S מינ' co S, $\hat{f}_S := \{x \in X : \hat{f}_S(x) \neq f(x)\}$, מינ' co S מינ' co D מינ' co A

מינ' co S מינ' co D מינ' co A מינ' co S מינ' co D מינ' co A

מינ' co S מינ' co D מינ' co A מינ' co S מינ' co D מינ' co A

בנוסף לטענה ש $\sum \hat{f}_s > L_{D,f}(\hat{f}_s) \geq \delta$, ניקח סט של S מוגבל ב $\sum \hat{f}_s \wedge S = \emptyset$

$$\sum \hat{f}_s \wedge S = \emptyset$$

לעתה נוכיח ש $L_{D,f}(\hat{f}_s) \geq \varepsilon$:

נניח $\exists x \in D$ כך ש $\hat{f}_s(x) \neq f(x) \geq \varepsilon$.

$$\mathbb{P}_D [L_{D,f}(\hat{f}_s) \geq \varepsilon] \leftarrow \mathbb{P}_D [\hat{f}_s(x) \neq f(x) \geq \varepsilon] \stackrel{\downarrow}{=} \mathbb{P}_D [\delta(\hat{f}_s) \geq \varepsilon]$$

כגון ר

הוכחנו ש $\sum \hat{f}_s \wedge S = \emptyset$ מוגבל ב $\hat{f}_s(x) \neq f(x) \geq \varepsilon$.

בנוסף לאפשרות $\hat{f}_s(x) \neq f(x) \geq \varepsilon$ ניקח סט S מוגבל ב $\sum \hat{f}_s \wedge S = \emptyset$ ו $\delta(\hat{f}_s) \geq \varepsilon$.

$$\mathbb{P}_D [L_{D,f}(\hat{f}_s) \geq \varepsilon] = \mathbb{P}_D [\delta(\hat{f}_s) \geq \varepsilon] = \mathbb{P}_D [\sum \hat{f}_s \wedge S = \emptyset] \leq e^{-m\varepsilon}$$

אנו כה

פונקצי

הוכחנו ש $\sum \hat{f}_s \wedge S = \emptyset$ מוגבל ב $\delta(\hat{f}_s) \geq \varepsilon$.

c)

בנוסף לטענה ש $\sum \hat{f}_s \wedge S = \emptyset$ מוגבל ב $\delta(\hat{f}_s) \geq \varepsilon$:

$$\mathbb{P}_D [L_{D,f}(\hat{f}_s) \geq \varepsilon] \leq e^{-m\varepsilon}$$

Theorem 1.1 \Rightarrow $\lim_{n \rightarrow \infty} \mathbb{P}[\text{AC}] = 1$

ולכן $\forall \varepsilon > 0 \exists N$ כך ש $\mathbb{P}[\text{AC}] > 1 - \varepsilon$.

הוכחה:

$$\mathbb{P}_D \left[\exists_{h \in H} : L_D(h) > \varepsilon \right] \leq |H| \cdot e^{-m\varepsilon}$$

הוינט והפיגורציה
בניהם
היפרbole
גיאומטריה
טופולוגיה
לעומת נועם

כדי לאריך נסוך |תקופה| נועם שפואת אקס. וזו גודל מושג

אנו כ.א. בוגר ידוי היפרbole שפואת גיאומטריה באנדרה גיאומטריה היפרbole ורגדן:

$$\mathbb{P}_D (L_{D,f}(A(s_m)) > \varepsilon) \leq |H| \cdot e^{-m\varepsilon}$$

$$|H| \cdot e^{-m\varepsilon} \leq \delta ; \delta$$

ולכן:

$$\mathbb{P}_D (L_{D,f}(A(s_m)) > \varepsilon) \leq \delta$$

ולא יותר אוניברסלי

$$\mathbb{P}_D (L_{D,f}(A(s_m)) < \varepsilon) \geq 1 - \delta$$

2)

הוכחה של קיומו של מוקד פאץ' בפונקציית הדרישה

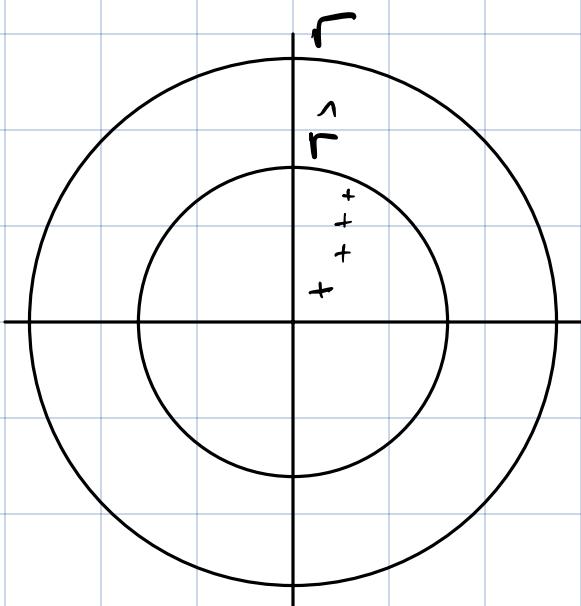
$$\mathbb{P}_D (L_{D,f}(A(s_m)) < \varepsilon) \geq 1 - \delta$$

הוכחה של קיומו של מוקד פאץ' בפונקציית הדרישה

הוכחה של קיומו של מוקד פאץ' בפונקציית הדרישה

$$r = \max \{ \|x_i\|_2 : y_i = 1 \}$$

כך נובע מה הטענה:



הנחתה קבוצה חיצונית נספנת ופונקציית פוטנציה גראDED צפינית וcontinous.

לפננו מוקדש מרחב \mathbb{R}^d ופונקציית loss כפונקציית מילוי $L_D(r) = P_{x \sim D}[r < \|x\|_2 \leq R]$.

$$P_\delta(L_D(r) < \epsilon) > 1 - \delta$$

(ב) מגדיר קבוצה S_r כ $\{x \in \mathbb{R}^d : \|x\|_2 \leq r\}$ ופונקציית loss כ $L_S(r) = P_{x \sim S_r}[L_D(x) \geq \epsilon]$

הנחתה קבוצה S_r כ $\{x \in \mathbb{R}^d : \|x\|_2 \leq r\}$ ופונקציית loss כ $L_S(r) = P_{x \sim S_r}[L_D(x) \geq \epsilon]$

הנחתה קבוצה S_r כ $\{x \in \mathbb{R}^d : \|x\|_2 \leq r\}$ ופונקציית loss כ $L_S(r) = P_{x \sim S_r}[L_D(x) \geq \epsilon]$

הנחתה קבוצה S_r כ $\{x \in \mathbb{R}^d : \|x\|_2 \leq r\}$ ופונקציית loss כ $L_S(r) = P_{x \sim S_r}[L_D(x) \geq \epsilon]$

הנחתה קבוצה S_r כ $\{x \in \mathbb{R}^d : \|x\|_2 \leq r\}$ ופונקציית loss כ $L_S(r) = P_{x \sim S_r}[L_D(x) \geq \epsilon]$

הנחתה קבוצה S_r כ $\{x \in \mathbb{R}^d : \|x\|_2 \leq r\}$ ופונקציית loss כ $L_S(r) = P_{x \sim S_r}[L_D(x) \geq \epsilon]$

$(1 - \epsilon)^m < \epsilon$ ו $m > 0$:

$$P(L_D(r) > \epsilon) \leq (1 - \epsilon)^m \leq e^{-m\epsilon}$$

כפונקציית loss

$$e^{-m\epsilon} \leq \delta \quad ; \quad \text{מגדיר } m = \frac{\ln \delta}{-\epsilon}$$

: ln sup δ → 0

$$-\varepsilon m \leq \ln \delta$$

$$m \geq \frac{\ln(\frac{1}{\delta})}{\varepsilon}$$

: מגדיר גורם נזק

$$\mathbb{P}_D(L_{D,f}(A(s_m)) > \varepsilon) \leq \delta$$

מגדיר גורם נזק ↓

$$\mathbb{P}_D(L_{D,f}(A(s_m)) < \varepsilon) > 1 - \delta$$

PAC אינטראציית הדרישה PAC נס' נס' H נזק

$$\boxed{1} \text{ אינטראציית } \frac{\ln(\frac{1}{\delta})}{\varepsilon} := \text{ נזק}$$

3)

: נזק Uniform Convergence H יסוד

$$\mathbb{P}^m(\{s \in (X \times Y)^m \mid \forall h \in H \quad |L_s(h) - L_D(h)| < \varepsilon\}) \geq 1 - \delta$$

: נזק PAC אינטראציית הדרישה PAC נס' נס' H נזק

$$L_D(A(S)) \leq \min_{h^* \in H} L_D(h^*) + \varepsilon$$

$$\text{אינטראציית הדרישה} - h^* = \min_{h \in H} L_D(h) \rightarrow \text{ינטראציית הדרישה}$$

$$\text{אינטראציית הדרישה} - h_S = \min_{h \in H} L_S(h) \stackrel{\text{ERM}}{=} A(S)$$

: PAC אינטראציית הדרישה PAC נס' נס' H נזק

$$\forall h \in H \quad |L_s(h) - L_D(h)| \leq \frac{\epsilon}{2} \quad (*)$$

הנחות: $\epsilon \rightarrow 0$

$$L_D(A(s)) = L_D(h_s) \stackrel{(*)}{\leq} L_s(h_s) + \frac{\epsilon}{2} \leq L_s(h^*) + \frac{\epsilon}{2} \stackrel{(*)}{\leq} L_D(h^*) + \frac{\epsilon}{2} + \frac{\epsilon}{2} = L_D(h^*) + \epsilon$$

↑
ERM
↑
uniform convergence
h^{*}



ר' מ' פ' א' ב' כ' ו' נ' ס' נ' ש' ר' מ' פ'

ר' מ' פ' א' ב' כ' ו' נ' ס' נ' ש' ר' מ' פ'

ר' מ' פ' א' ב' כ' ו' נ' ס' נ' ש' ר' מ' פ'

$$m_H(\epsilon, \delta) \leq m^{VC}\left(\frac{\epsilon}{2}, \delta\right)$$

ר' מ' פ' א' ב' כ' ו' נ' ס' נ' ש' ר' מ' פ'

1.3: VC-Dimension

$$1) h_i(x) = \left(\sum_{i \in I} x_i \right) \bmod 2$$

, $Y = \{0, 1\}$, $X = \{0, 1\}^n$

ר' מ' פ' א' ב' כ' ו' נ' ס' נ' ש' ר' מ' פ'

ר' מ' פ' א' ב' כ' ו' נ' ס' נ' ש' ר' מ' פ'

ר' מ' פ' א' ב' כ' ו' נ' ס' נ' ש' ר' מ' פ'

ר' מ' פ' א' ב' כ' ו' נ' ס' נ' ש' ר' מ' פ'

ר' מ' פ' א' ב' כ' ו' נ' ס' נ' ש' ר' מ' פ'

ר' מ' פ' א' ב' כ' ו' נ' ס' נ' ש' ר' מ' פ'

ר' מ' פ' א' ב' כ' ו' נ' ס' נ' ש' ר' מ' פ'

$$\boxed{VC\dim(H) \leq n}$$

ר' מ' פ' א' ב' כ' ו' נ' ס' נ' ש' ר' מ' פ'

$$\text{למונטגנו ש } x_3 = \begin{pmatrix} 0 \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}, \quad x_2 = \begin{pmatrix} 0 \\ 0 \\ 1 \\ \vdots \\ 0 \end{pmatrix}, \quad x_1 = \begin{pmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

למונטגנו ש $y \in \{0,1\}^n$ מוגדרת כפונקציית סטיון. נסמן $I = \{j : y_j = 1\}$.

לעתה נוכיח את הטענה. בואו נוכיח בדידותה של I .

בנוסף לכך, נוכיח ש $\text{VC dim}(H) \geq n$.

הוכחה:

$$\text{VC dim}(H) = n$$

בנוסף לכך, נוכיח ש $\text{VC dim}(H) \leq n$.

2). $H_2 \subseteq H_1$ ופונקציית סטיון H_1 מוגדרת כפונקציית סטיון H_2 . נוכיח ש $\text{VC dim}(H_1) \leq \text{VC dim}(H_2)$.

בנוסף לכך, נוכיח ש $\text{VC dim}(H_2) \leq \text{VC dim}(H_1)$.

בכדי證明 $H_1 \subseteq H_2$, נוכיח ש $\forall S \subseteq \{1, \dots, n\}$ קיימת פונקציית סטיון f_{H_1} אשר מוגדרת כפונקציית סטיון f_{H_2} על S .

בכדי證明 $\text{VC dim}(H_2) \leq \text{VC dim}(H_1)$, נוכיח ש $\forall S \subseteq \{1, \dots, n\}$ קיימת פונקציית סטיון f_{H_2} אשר מוגדרת כפונקציית סטיון f_{H_1} על S .

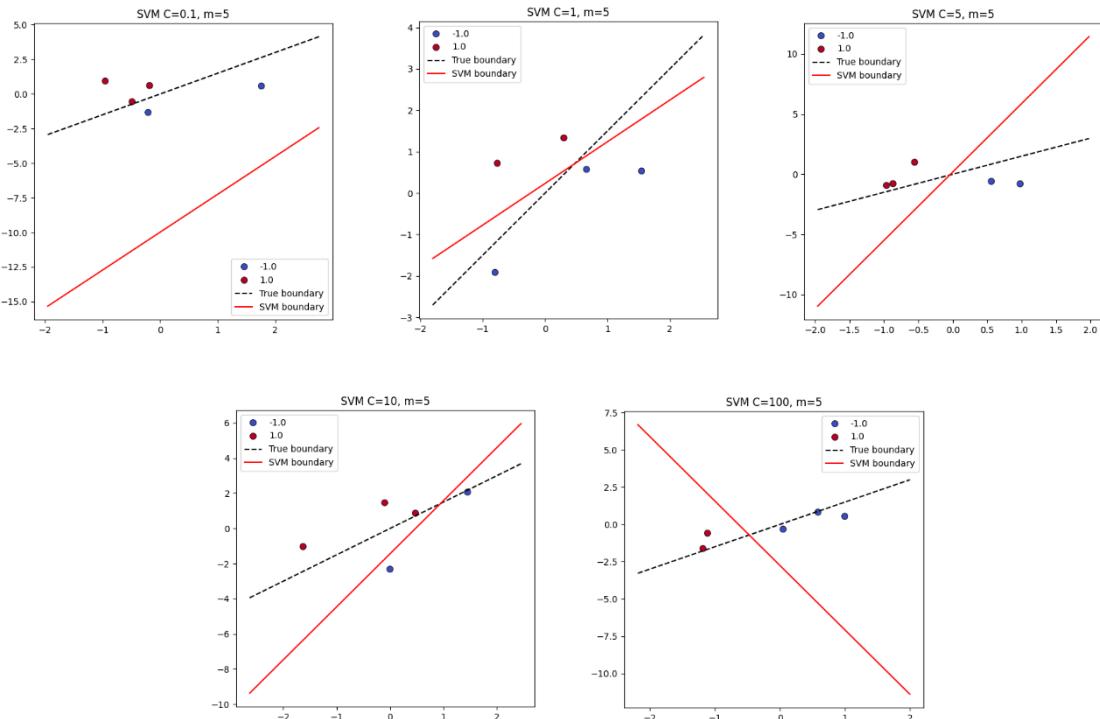
$$\text{VC dim}(H_2) \leq \text{VC dim}(H_1)$$

Practical Part:

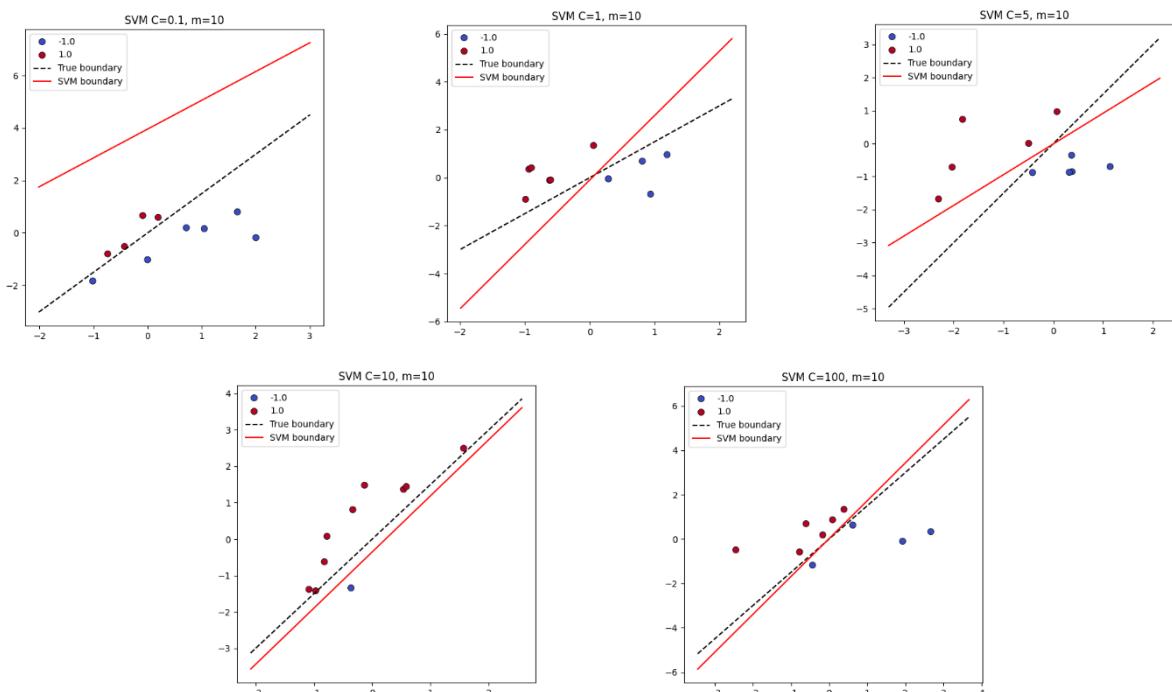
SVM:

1)

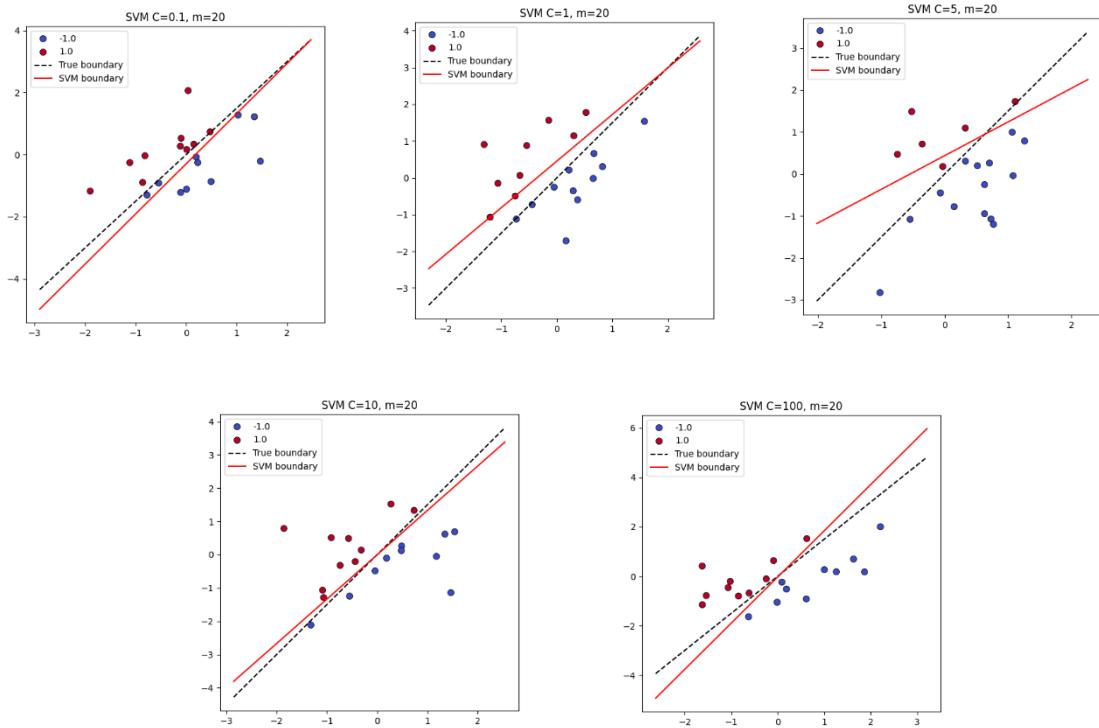
$M = 5:$



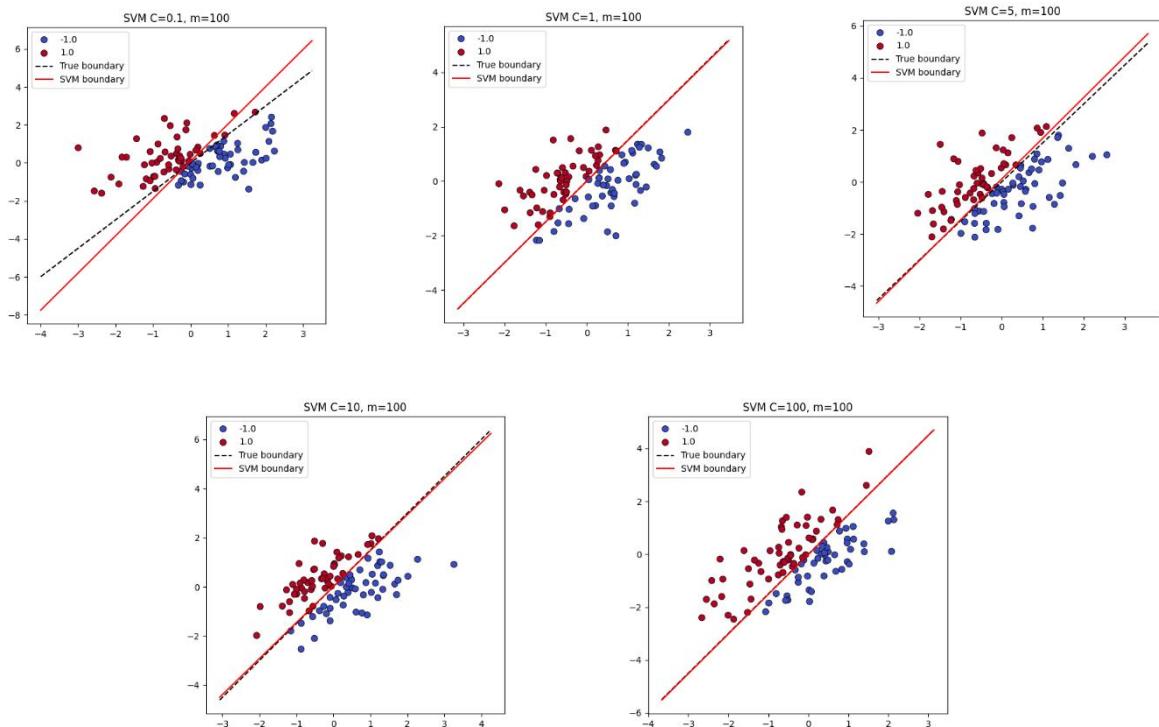
$M = 10:$



M = 20:



M = 100:

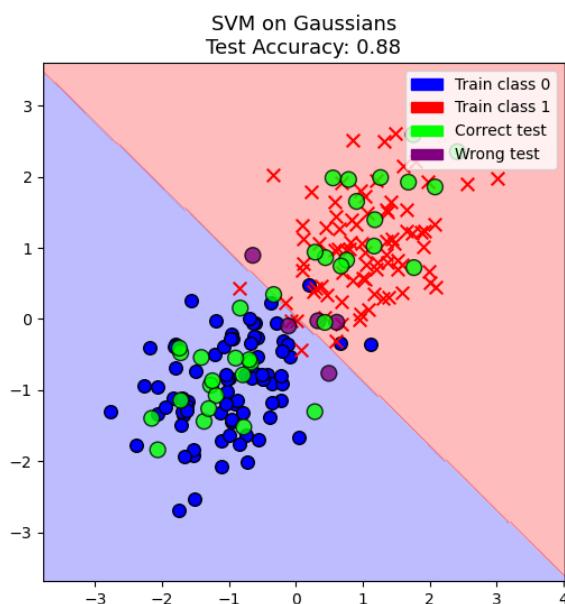
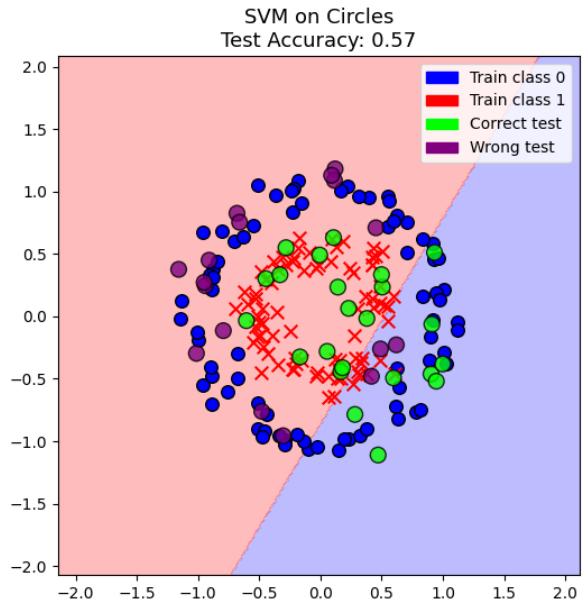
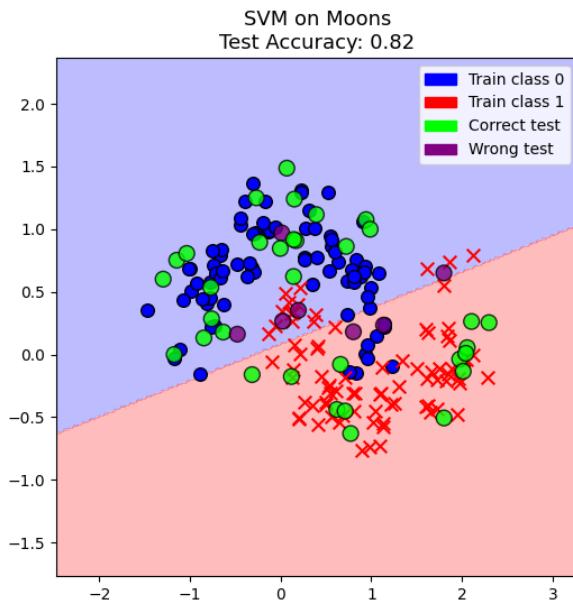


(2) ב-SVM ערך C מייצג כמה "עונש" אנו נתונים על כל טעות של המודל. כלומר ככל שהC יותר קטן המודל מאפשר יותר טיעיות על מנת ליצור את המרווח הגדול ביותר. זה תואם את הגрафים שקיבלנו. ניתן לראות שככל שהC יותר גדול הקו עושה פחות טיעיות בסיווג ובעירקו עם מרוחק קטן יותר מהדגם הקרוב ביותר אליו. בהתאם ככל שהC קטן יותר הסיווג עושה יותר טיעיות אך ממקסם את המרווח.

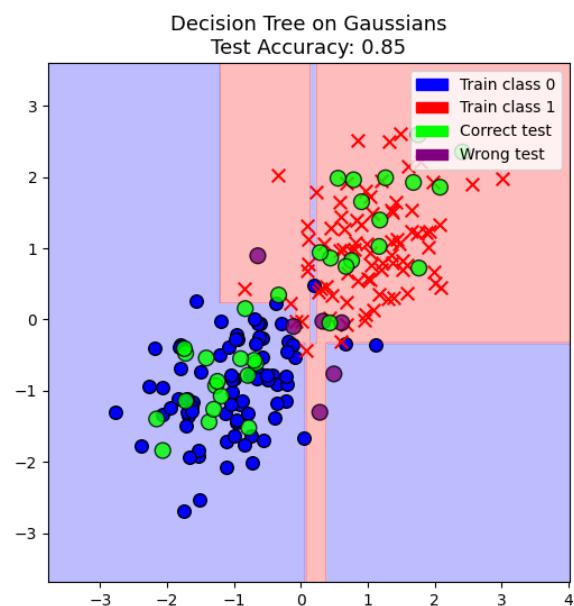
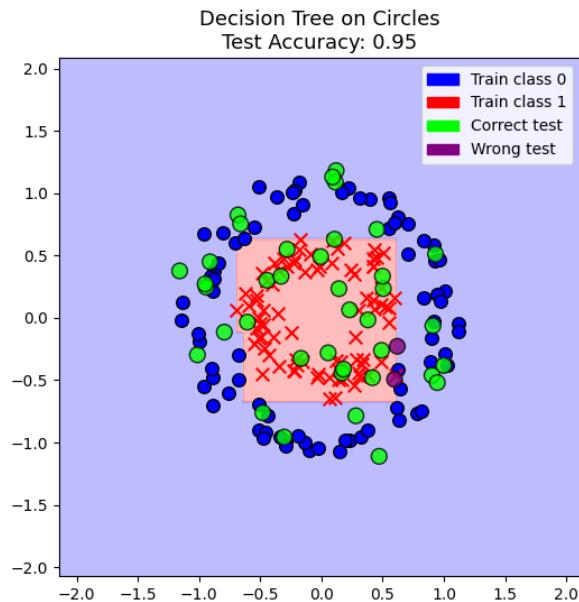
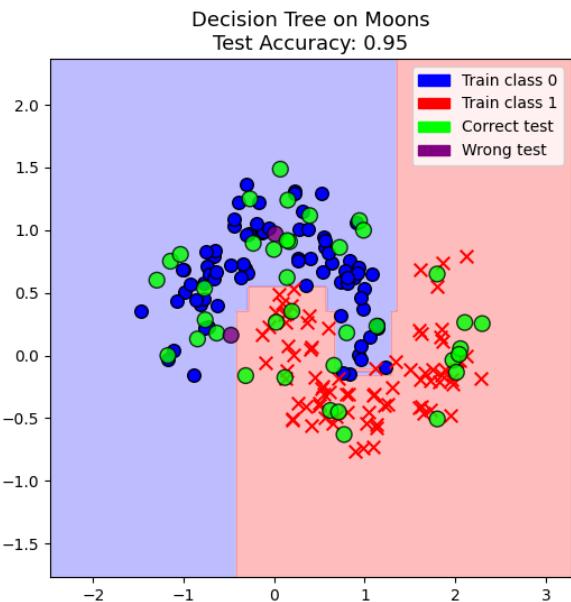
(3) לפי עקרונות למידת PAC ככל שיש יותר דוגמאות לומר M גדול מוביל לכך שאפסילון (מרוחק הטיעות) יקטן בהסתברות גבוהה יותר. זה מתבטא באמצעות סיבוכיות הדגם שאומරת כמה דוגמאות צריך על מנת להבטיח שהגדר קטנה מפאסילון. וכן נשים לב מהגרפים שקיבלנו שככל שM קטן יותר מודל SVM יוצר סיווג פחות מדויק עם רעש שככל הנראה יחזיר טיעיות על העולם האמיתי בהסתברות די גבוהה (ניתן לראות שקו הסיווג שהמודל העביר המסומן באדום רחוק מאוד מקו הרפרדה האמיתי המסומן בשחור). וכן ככל שהמספר הדוגמאות עולה ככל הcano גודל המודל מעביר מסוווג בצורה טובה יותר את הדוגמאות וככל הנראה יוביל להסתברות הרבה יותר גבוהה לסייע לפאסילון (המייצג את טווח הטיעות) ניתן לראות זאת גם על ידי הקרבה של קו הסיווג שהמודל העביר לקו המרווח האמיתי.

Classification Boundaries and Model Comparison:

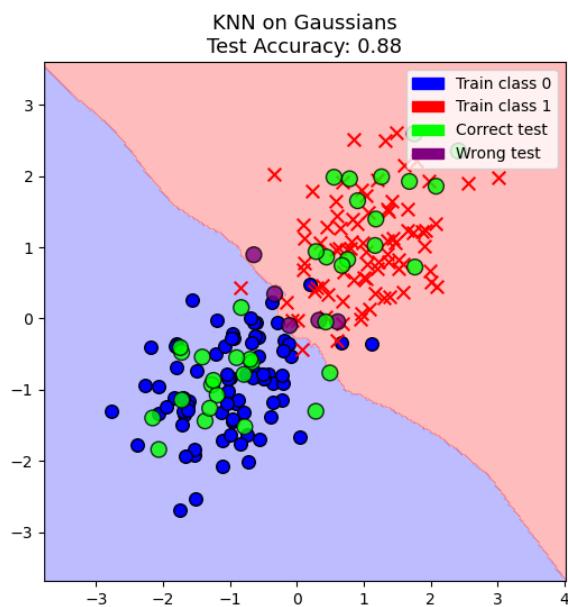
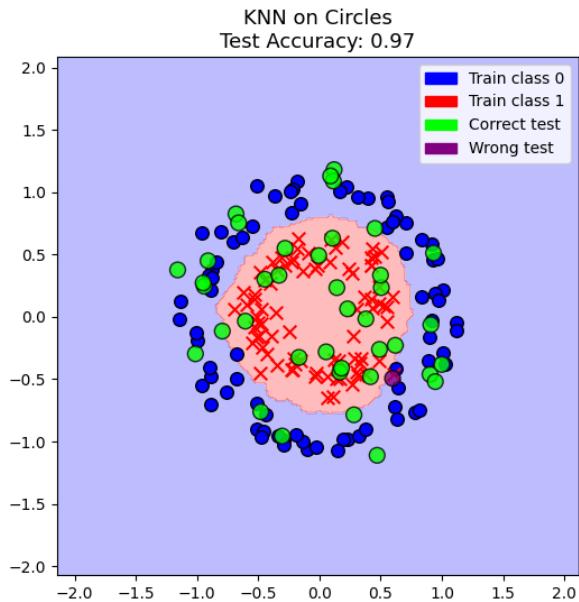
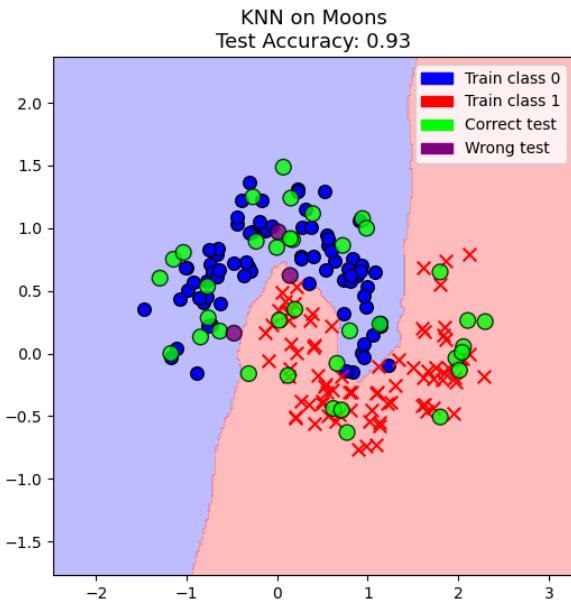
SVM:



Decision Tree:



KNN:



(2) Moons-Dגימות עם הפרדה בצורת ירח - לדאטה סט זהה המודל הטוב ביותר היה עז החלטות לאחר מacen KNN ולבסוף SVM. תוצאה זאת הגיונית מאחר ולסוג דאטה זה יש הכי הרבה "התערבות" מרוחבית של שני הקלאסים, וכן הגיוני של SVM יהיה הכי קשה לסוג מאחר ולא קיים קו לינארי שיעשה הפרדה טובה בין הקלאסים לא בגין עז החלטות וNNK הגיוני שהתוצאה תהיה טובה יותר ודומה כי יותר פשוט להגיע לצורה הנדרשת ע"י סוג הפעולה שלהם.

Circles- דגימות עם הפרדה מעגלית – בדומה לMOONS המודל הגרוע ביותר הוא SVM מאותה סיבה, הדאטה לא מחולק בצורה לינארית וכן לא יהיה אפשרי להעיבר קו ישר שיעשה סיווג טוב. NNK ועשה את הסיווג הטוב ביותר ואזה הגיוני בשל כך שהוא יכול ליצור הפרדה דינאמית מעגלית שאינה תלולה בצורה פיזור הדאטה וענ' החלטות התקשה טיפה יותר בשל כך שהוא יוצר מבנים שייתר קשה לחפות אוטם עם צורת המעגל של הדאטה.

Gaussians- שלושת סוגי הסיווג קיבלו פה תוצאה טובה וזאת בשל העבודה שהדאטה מסודר בצורה נוחה לשולשות המודלים להוציא תוצאה אופטימלית, יש הפרדה וקרבה מסוימת בין הדגימות כך שככל שלושת המודלים מצלחים להוציא סיווג טוב.

(3) SVM- האלגוריתם מייצר גבול לינארי ישיר המחלק לשני חצאים לפי המרחק הגדול ביותר מהנקודות הקרובות אליו ביותר משני הקלאסים.

ענ' החלטות- האלגוריתם יוצר מבנים לפי שני הצירם ועובד על הדגימות תוך חלוקה של המרחב לשניים בצורה רקורסיבית וסיווג על ידי רוב מלבן שנוצר עד לעצירה על ידי קביעת פרמטר שמשמעותו מתי לעצור את החלוקה. אלגוריתם זה מחלק את המרחב ל"קופסאות" בצורה מלבן שלכל אחת סיווג אחר. עובד טוב כשהדאטה "מרובע" באופיו.

NNK – האלגוריתם מקבל פרמטר K ומסוויג כל נקודה לפי סיווג K השכנים הקרובים אליה ביותר וכן הוא יוצר גבולות מאוד גמישים ובצורות לא סדירות (לעתים סוג של מובלעות) בהתאם לדאטה עצמו.