

Theoretical part:

1.1 Regularization

a) $X \in \mathbb{R}^{m \times d}$, $y \in \mathbb{R}^m$ $X^T X = P \in \mathbb{R}^{d \times d}$

$\hat{w} = \text{LS solution}$, $\hat{w}_\lambda = \text{ridge solution } \lambda \geq 0$

$$y = Xw + \epsilon, \epsilon \sim N(0, \sigma^2), \text{Bias}(\hat{w}) = 0$$

$$\mathbb{E}(w) = \mathbb{E}(w + (X^T X)^{-1} X^T \epsilon) = w + (X^T X)^{-1} X^T \mathbb{E}(\epsilon) = w$$

$$\hat{w}_\lambda = (X^T X + \lambda I_d)^{-1} (X^T y) \quad : \text{§3}$$

∴ Ridge solution is a more robust solution than LS

$$\hat{w}_\lambda = (X^T X + \lambda I_d)^{-1} X^T y = \arg \min \|Xw - y\|^2 + \lambda \|w\|^2$$

For small λ the ridge solution is close to LS

$$\hat{w} = (X^T X)^{-1} X^T y$$

$$\downarrow \quad I_d$$

$$(X^T X + \lambda I_d)^{-1} (X^T X) \cdot (X^T X)^{-1} X^T y = (X^T X + \lambda I_d)^{-1} X^T y$$



לעומת מינימום כפופה ל-
הטמפרטורה ו- σ

ב) $\hat{w}_x = \frac{1}{\lambda} (X^T X + \lambda I_d)^{-1} X^T y$

b) $\hat{w}_x = (X^T X + \lambda I_d)^{-1} (X^T y) \cdot \hat{w}$

$$E(\hat{w}_x) = E[(X^T X + \lambda I_d)^{-1} (X^T y) \cdot \hat{w}]$$

$$\text{לפניהם } E(\hat{w}) = w$$

$$= (X^T X + \lambda I_d)^{-1} (X^T y) \cdot E(\hat{w}) = \boxed{(X^T X + \lambda I_d)^{-1} X^T y \cdot w}$$

רעיון גאותה מושג בדרכו רותה נזקיה בקיירה

השאלה היא האם ניתן לרשום $X^T y$ כהצמדה של y ו- X

w מושג באמצעות y ו- X בפונקציית פירסום f

c) $\lambda > 0$ פירוש $E(\hat{w}_x) \neq w$ bias $\neq 0$ \Rightarrow גאותה

c) $\text{Var}(\hat{w}_x) = \text{Var}(A_x \hat{w}) = A_x \cdot \text{Var}(\hat{w}) A_x^T$

$$= A_x \underbrace{\sigma^2}_{\text{noise}} (X^T X)^{-1} A_x^T = \sigma^2 A_x (X^T X)^{-1} A_x^T$$

d) $\text{MSE}(\hat{w}_x) = E[\|\hat{w}_x - w\|^2] = E[(\hat{w}_x - E(\hat{w}_x))^T (\hat{w}_x - E(\hat{w}_x))]$

$$= \|E(\hat{w}_x - w)\|^2 + E(\|\hat{w}_x - E(\hat{w}_x)\|^2)$$

bias

Var

$$\text{bias}^2(x) = \left(E(\hat{w}_x) - E(\hat{w}) \right)^2 = \left((A_x - I) w \right)^2$$

$$\text{Var}(x) = \sigma^2 \text{Tr}\left(A_x (x^T x)^{-1} A_x^T\right) =$$

מינימום
הכפלה
בנורמליזציה
המינימום

↙

$$\boxed{\text{MSE}(\hat{x}_\lambda) = \| (A_x - I) w \|^2 + \sigma^2 \text{Tr}\left(A_x (x^T x)^{-1} A_x^T\right)}$$



e)

אם $\lambda = 0$ אז מינימום שגיאה מינימום נורמליזציה
 אם $\lambda \rightarrow \infty$ שגיאה מינימום נורמליזציה
 פונקציית bias כ- $\lambda = 0$ היא מוגבהת וגדלה
 הגדלה כ- $\lambda \rightarrow \infty$ מוגבהת וגדלה
 כלומר x מופעל בפונקציית variance מינימום נורמליזציה
 ridge regression כ- $\lambda = 0$ מוגבהת וגדלה נורמליזציה
 מוגבהת וגדלה כ- $\lambda \rightarrow \infty$ מינימום נורמליזציה

1.2-

a) $X \in \mathbb{R}^{m \times d}$, $y \in \mathbb{R}^m$, $L \in \mathbb{R}^{k \times d}$, $X^T X - L^T L$ דוגמא

$\underset{w \in \mathbb{R}^d}{\operatorname{argmin}} (||Xw - y||^2 + ||Lw||^2)$ סולו כרוכסן גודל רדיאן

פונקציית ריבוק נסיעה של פונקציה ריבוקית ריבוקית

Ridges פונקציית ריבוקת ריבוקת ריבוקת

$$||Xw - y||^2 + ||Lw||^2 = (Xw - y)^T (Xw - y) + (Lw)^T (Lw)$$

$$= w^T X^T X w - 2y^T X w + y^T y + w^T L^T L w$$

$$= w^T (X^T X + L^T L) w - 2y^T X w + y^T y$$

$$= w^T (X^T X + L^T L) w - 2y^T X w + y^T y$$

$$w^T A w = 2Aw, b^T w = b \quad : w \cdot \text{deg} \rightarrow \text{deg}, \text{deg}$$

$$\nabla = 2(X^T X + L^T L)w - 2X^T y$$

: פונקציית דרגה א-סימטרית

$$\cancel{\nabla} (X^T X + L^T L)w = \cancel{\nabla} X^T y$$

$$W_L^{T,K} = \boxed{w = (X^T X + L^T L)^{-1} X^T y}$$



b)

הנורמליזציה מושגת באמצעות $X^T X$

בנוסף לכך, $X^T X + L^T L$ מוגדר y ו- x .

כך, שיטתה פירושה ביצירת מatrice קומפקטת $L^T L$ ו- $X^T X + L^T L$.

於是, זה מגדיר מatrice קומפקטת PSD מ- C_N על $L^T L$.

לדוגמא, $x = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$, $y = \begin{bmatrix} 5 \\ 6 \end{bmatrix}$ ו- $L^T L = \begin{bmatrix} 20 & -14 \\ -14 & 10 \end{bmatrix}$.

c)

$$X = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}, \quad y = \begin{bmatrix} 5 \\ 6 \end{bmatrix} \Rightarrow X^T = \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix}$$

$$\text{LS} \rightarrow \hat{w} = (X^T X)^{-1} X^T y$$

i)

$$\hat{w} = \left(\begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \right)^{-1} \cdot \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix} \cdot \begin{bmatrix} 5 \\ 6 \end{bmatrix}$$

$$= \begin{bmatrix} 10 & 14 \\ 14 & 20 \end{bmatrix}^{-1} \cdot \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 5 \\ 6 \end{bmatrix} = \frac{1}{200-196} \begin{bmatrix} 20 & -14 \\ -14 & 10 \end{bmatrix} \cdot \underbrace{\begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 5 \\ 6 \end{bmatrix}}_{x^T y}$$

$$= \frac{1}{4} \begin{bmatrix} 20 & -14 \\ -14 & 10 \end{bmatrix} \cdot \begin{bmatrix} 23 \\ 34 \end{bmatrix} = \begin{bmatrix} 5 & -\frac{14}{4} \\ -\frac{14}{4} & 2.5 \end{bmatrix} \begin{bmatrix} 23 \\ 34 \end{bmatrix} = \boxed{\begin{bmatrix} -4 \\ 4.5 \end{bmatrix}}$$

ii)

$$\underline{\lambda = 1}$$

$$\hat{w}_{\text{Ridge}} = (X^T X + \lambda I_2)^{-1} X^T y$$

ולא נזקם:

$$x^T y = \begin{bmatrix} 23 \\ 34 \end{bmatrix}$$

$$x^T x = \begin{bmatrix} 10 & 14 \\ 14 & 20 \end{bmatrix}$$

1 Ridge $\hat{w}_x = \left(\begin{bmatrix} 10 & 14 \\ 14 & 20 \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \right)^{-1} \begin{bmatrix} 23 \\ 34 \end{bmatrix}$

$$= \begin{bmatrix} 11 & 14 \\ 14 & 21 \end{bmatrix}^{-1} \begin{bmatrix} 23 \\ 34 \end{bmatrix} = \frac{1}{21 \cdot 11 - 196} \begin{bmatrix} 21 & -14 \\ -14 & 11 \end{bmatrix} \begin{bmatrix} 23 \\ 34 \end{bmatrix}$$

$$= \begin{bmatrix} \frac{21}{35} & -\frac{14}{35} \\ -\frac{14}{35} & \frac{11}{35} \end{bmatrix} \begin{bmatrix} 23 \\ 34 \end{bmatrix} = \boxed{\begin{bmatrix} 0.2 \\ 1.48 \end{bmatrix}}$$

iii) $\hat{w}^{Tik} = (x^T x + L^T L)^{-1} x^T y$ $L = \begin{bmatrix} 0 & 0 \\ 0 & 2 \end{bmatrix}$
p. 765 f. 5. Auflage

$L^T L = \begin{bmatrix} 0 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 0 & 0 \\ 0 & 2 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 4 \end{bmatrix}$, $x^T x = \begin{bmatrix} 10 & 14 \\ 14 & 20 \end{bmatrix}$, $x^T y = \begin{bmatrix} 23 \\ 34 \end{bmatrix}$

$$L^T L = \begin{bmatrix} 0 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 0 & 0 \\ 0 & 2 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 4 \end{bmatrix}$$

$$\hat{w}^{Tik} = \left(\begin{bmatrix} 10 & 14 \\ 14 & 20 \end{bmatrix} + \begin{bmatrix} 0 & 0 \\ 0 & 4 \end{bmatrix} \right)^{-1} \begin{bmatrix} 23 \\ 34 \end{bmatrix} = \left(\begin{bmatrix} 10 & 14 \\ 14 & 24 \end{bmatrix} \right)^{-1} \begin{bmatrix} 23 \\ 34 \end{bmatrix}$$

$$= \frac{1}{240 - 196} \begin{bmatrix} 24 & -14 \\ -14 & 10 \end{bmatrix} \begin{bmatrix} 23 \\ 34 \end{bmatrix} = \begin{bmatrix} \frac{24}{44} & -\frac{14}{44} \\ -\frac{14}{44} & \frac{10}{44} \end{bmatrix} \begin{bmatrix} 23 \\ 34 \end{bmatrix} = \boxed{\begin{bmatrix} 1.72 \\ 0.41 \end{bmatrix}}$$

i) $\|\vec{w}\| = \sqrt{4^2 + 4.5^2} = 6.02$

$$\left\| \vec{w}_{\lambda=1}^{\text{Ridge}} \right\| = \sqrt{0.2^2 + 1.49^2} = 1.493$$

$$\left\| \vec{w}^{\text{Tikh}} \right\| = \sqrt{1.72^2 + 0.41^2} = 1.765$$



$\left\| \vec{w}_{\lambda=1}^{\text{Ridge}} \right\| < \left\| \vec{w}^{\text{Tikh}} \right\| < \left\| \vec{w} \right\|$

לטפל בפתרונות מודים או הדראה כי לדוגמה \vec{w} נקבע איקי 1 האז'ן

ולא נזרה פג זר דוגמם הרובוט איזה יפה גורם כדוגמתם הטעינה השוואת שוכן Ridge נהייה פג של המודול ואילו שוכן הרובוט גורם הטעינה השוואת שוכן Ridge

בשוויה לנו זר הדראה כי רצינית נוקה איזה איזה דואו דיאו זר

בנוסף לאז'ן טיקוןוב רצינית נוקה איזה איזה דואו דיאו זר
בנוסף לאז'ן טיקוןוב רצינית נוקה איזה איזה דואו דיאו זר
בנוסף לאז'ן טיקוןוב רצינית נוקה איזה איזה דואו דיאו זר
בנוסף לאז'ן טיקוןוב רצינית נוקה איזה איזה דואו דיאו זר

ככ. ספ' הושען דמיון הדראה מתקיימת קראנו ור' ל

ברכון הנציגות הדראה מתקיימת קראנו ור' ל


חישוב Ridge דמיון מתקיימת קראנו ור' ל

בכ. ספ' הדראה מתקיימת קראנו ור' ל

הדראה מתקיימת קראנו ור' ל
הדראה מתקיימת קראנו ור' ל
הדראה מתקיימת קראנו ור' ל
הדראה מתקיימת קראנו ור' ל

1.2 - PCA -

$$x_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad x_2 = \begin{bmatrix} -1 \\ 1 \end{bmatrix}, \quad x_3 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$




a) $\bar{x} = \frac{1}{3} \sum_{i=1}^3 x_i = \frac{1}{3} \begin{pmatrix} 1-1+1 \\ 2+1+1 \end{pmatrix} = \begin{pmatrix} 1 \\ 4 \end{pmatrix} = \boxed{\begin{pmatrix} \frac{1}{3} \\ \frac{4}{3} \end{pmatrix}}$

$$z_1 = \begin{pmatrix} 1 \\ 2 \end{pmatrix} - \begin{pmatrix} \frac{1}{3} \\ \frac{4}{3} \end{pmatrix} = \begin{pmatrix} \frac{2}{3} \\ \frac{2}{3} \end{pmatrix}$$

$$z_2 = \begin{pmatrix} -1 \\ 1 \end{pmatrix} - \begin{pmatrix} \frac{1}{3} \\ \frac{4}{3} \end{pmatrix} = \begin{pmatrix} -\frac{4}{3} \\ -\frac{1}{3} \end{pmatrix}$$


$$z_3 = \begin{pmatrix} 1 \\ 1 \end{pmatrix} - \begin{pmatrix} \frac{1}{3} \\ \frac{4}{3} \end{pmatrix} = \begin{pmatrix} \frac{2}{3} \\ -\frac{1}{3} \end{pmatrix}$$



b)

$$\Sigma = \begin{bmatrix} 8 & 2 \\ 2 & 9 \end{bmatrix} \Rightarrow \lambda = 0.956 \quad \alpha = \begin{pmatrix} -0.9571 \\ -0.2898 \end{pmatrix}$$

(Cores röd pion)



c)

$$V^+ z_1 = -0.83$$

$$V^+ z_2 = 1.32$$

$$V^+ z_3 = -0.48$$

d)


$$\check{v}(v^T z_1) = \begin{pmatrix} -0.9571 \\ -0.2898 \end{pmatrix} \cdot 0.83 = \begin{pmatrix} 0.796 \\ 0.241 \end{pmatrix}$$

$$\check{v}(v^T z_2) = \begin{pmatrix} -0.9571 \\ -0.2898 \end{pmatrix} \cdot 1.32 = \begin{pmatrix} -1.314 \\ -0.394 \end{pmatrix}$$

$$\check{v}(v^T z_3) = \begin{pmatrix} -0.9571 \\ -0.2898 \end{pmatrix} \cdot 0.48 = \begin{pmatrix} 0.518 \\ 0.157 \end{pmatrix}$$

✓

e)



$$x_1^R = \begin{pmatrix} 1.12 \\ 1.574 \end{pmatrix}$$

$$x_2^R = \begin{pmatrix} -0.98 \\ 0.93 \end{pmatrix}$$

$$x_3^R = \begin{pmatrix} 0.85 \\ 1.49 \end{pmatrix}$$

$$V = \begin{pmatrix} \frac{1}{3} \\ \frac{3}{4} \end{pmatrix} + \begin{pmatrix} -0.9571 \\ -0.2898 \end{pmatrix} \alpha$$

$$2) \sum_i = x_i - \bar{x} , w^T w \rightarrow \delta_{123}$$

a)

$$\sum_{i=1}^m \|x_i - \bar{x} - w^T w(x_i - \bar{x})\|^2 = \sum_{i=1}^m \|z_i\|^2 - z_i^T w^T w z_i : \text{Eq 3}$$

$$z_i = x_i - \bar{x}$$

$$\sum_{i=1}^m \|x_i - \bar{x} - w^T w(x_i - \bar{x})\|^2 = \sum_{i=1}^m \|z_i - w^T w z_i\|^2$$

$$= \sum_{i=1}^m \|z_i\|^2 - 2 z_i^T w^T w z_i + \|w^T w z_i\|^2$$

↗
non 0
δδ

$$= \sum_{i=1}^m \|z_i\|^2 - 2 z_i^T w^T w z_i + z_i^T w^T w w^T w z_i$$

↗
non 0
δδ

$$\underline{\underline{w^T w}} \rightarrow \sum_{i=1}^m \|z_i\|^2 - 2 z_i^T w^T w z_i + z_i^T w^T w z_i$$

$w^T w w^T w = w^T w$

$$= \sum_{i=1}^m \|z_i\|^2 - z_i^T w^T w z_i$$



$$b) \sum_{i=1}^m z_i^T w^T w z_i = m \cdot \text{Tr}(w \Sigma w^T)$$

dfb

$a \in \mathbb{R}$

$$\text{Tr}(a) = a$$

$$\sum_{i=1}^m z_i^T w^T w z_i = \sum_{i=1}^m \text{Tr}(z_i^T w^T w z_i)$$

→ dfb

$$\text{Tr}(AB) = \text{Tr}(BA)$$

$$\Rightarrow \sum_{i=1}^m \text{Tr}(w z_i z_i^T w^T) \stackrel{\text{dfb}}{=} \text{Tr}\left(w \left(\sum_{i=1}^m z_i z_i^T\right) w^T\right)$$

$$\sum = \frac{1}{m} \sum_{i=1}^m (x_i - \bar{x})(x_i - \bar{x})^T = \frac{1}{m} \sum_{i=1}^m z_i z_i^T$$

→ dfb n = m

$$\Rightarrow \text{Tr}(w (m \cdot \sum) w^T) = m \cdot \text{Tr}(w \Sigma w^T)$$



$$c) w = \begin{bmatrix} v_1^T \\ \vdots \\ v_k^T \end{bmatrix} \quad \text{Tr}(w \Sigma w^T) = \sum_{j=1}^k v_j^T \Sigma v_j \quad : \text{dfb}$$

$$\text{Tr}(w \Sigma w^T) = \text{Tr}\left(\begin{bmatrix} v_1^T \\ \vdots \\ v_k^T \end{bmatrix} \cdot \sum \cdot \begin{bmatrix} v_1 & \dots & v_k \end{bmatrix}\right)$$

→ dfb
Trace

$$= \text{Tr}\left(\begin{bmatrix} v_1^T \cdot \sum \cdot v_1 & \dots & v_n^T \cdot \sum \cdot v_n \\ \vdots & \ddots & \vdots \\ v_k^T \cdot \sum \cdot v_k & \dots & v_1^T \cdot \sum \cdot v_1 \end{bmatrix}\right) = \sum_{j=1}^k v_j^T \Sigma v_j$$



ד) $\sum_{i=1}^m \|x_i - \bar{x} - w^\top w(x_i - \bar{x})\|^2 = \sum_{i=1}^m \|z_i\|^2 - z_i^\top w^\top w z_i$

$$= \underbrace{\sum_{i=1}^m \|z_i\|^2}_{\text{sum of squared distances}} - \underbrace{\sum_{i=1}^m z_i^\top w^\top w z_i}_{\text{sum of weighted distances}}$$

כגון בדרכו נקבע שפער השגיאה מוגדר כ

$$\sum_{i=1}^m z_i^\top w^\top w z_i$$

ובכך $w = \begin{bmatrix} v_1^\top \\ \vdots \\ v_k^\top \end{bmatrix}$ פירושו של דבר הוא ש

$$\sum_{i=1}^m z_i^\top w^\top w z_i = m \cdot \text{Tr}(w w^\top) = m \cdot \sum_{j=1}^k v_j^\top v_j$$

לכן מינימיזציית שפער השגיאה מוגדרת כ



המשמעותה היא

3)

$$x: \mathcal{S} \rightarrow \mathbb{R}^d \quad \sum \in \mathbb{R}^{d \times d} \quad V \in \mathbb{R}^d, \quad \|\sum\|_2 = 1$$

$$\mathbb{E}[x] = 0$$

ונוכיח כי y_1 PCA הוא מינימום של λ_1 (אנו)

בנוסף PCA הוא פונקציית כפיפה וולנטית, כלומר y_1 PCA מוגדר

y_1 PCA מוגדר כפיפה וולנטית, כלומר y_1 PCA מוגדר

$$V_1^T V_1 = \lambda_1 \quad \text{PCA} \quad \text{Normalization} \quad \text{Goal}$$

$$\|V\|=1 \quad \text{unitary } V \quad \text{for } \text{orthogonal } \text{matrix } \text{of } \text{size } n$$

$$\text{Var}(\langle V, X \rangle) \leq V_1^T V_1 = \lambda_1$$

$$\text{Var}(\langle V, X \rangle) = E((V^T X)^2) = V^T E[X X^T] V = V^T V = \lambda_v$$

בנוסף לORTHOGONALITY, PCA מגדיר ממד אחד ב-1D.

$$\text{Var}(\langle V, X \rangle) = \lambda_v \leq \lambda_1 = V_1^T V_1$$

בנוסף PCA מגדיר ממד אחד ב-1D.



1.3 - clustering:

a) True

প্রতি ক্লাসের মধ্যে প্রতিটি ক্লাসের মধ্যে দূরত্ব অনেক কম।
 C_{final} এর মধ্যে প্রতিটি ক্লাসের মধ্যে দূরত্ব অনেক বেশি।

b) False

ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক কম।
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক বেশি।
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক কম।

c) True

ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক কম।
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক বেশি।
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক কম।
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক বেশি।

d) True


ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক কম।
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক বেশি।
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক কম।
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক বেশি।

Practical part Answers:

Boosting:

0 noise:


1)



כפי שניתן לראות התוצאות תואמות את הציפיות- ככל שמספר הלומדים עולה שגיאת הקלאסיפיקציה יורדת, בערכיהם הקטנים יחסית השגיאה מאוד תנומתית אף במספר מסוים באיזור 25 לומדים שהגיאת מתיצבת ומשתפרת באופן איטי מאד כפונקציה של הגדלת מספר הלומדים. מוגמה זאת הגיונית מאחר שמספר לומדים מסוים התוצאות כבר ד' מתמחזרות ולהלומדים חוזרים על עצם ולכך מד'יקם בrama מאוד קטנה את השגיאה.


2)

AdaBoost Decision Boundaries at Different Iterations




ניתן לראות שבמספר לומדים נמוך גבול החלטה היה כל הדאטה ולכן ניתן שגיאיה גדולה ולא מדויקת אך ככל שמספר הלומדים עולה המהדק על הדאטה ונותן תוצאות איקוטיות יותר. בנוסף ניתן לראות שהגבול עצמו יהיה יותר ויותר מעגלי בהתאם למינימום של גוף החלטה והוא יכול לבדוק יותר ויותר גזמי החלטה לעובדים פיזיים כלומר יותר מלבדים לסמן על גוף ההחלטה ולכך הוא יכול לבדוק יותר ויותר את הגבול האמתי על הדאטה עצמו שנמצא בצורה מעגלית.

3)




4)



ניתן לראות בגרף הממושקל של נקודות על התפר של גבול ההחלטה היו משקלים יותר גדולים בהרבה מהנקודות הרחוקות מהגבול, זאת תוצאה הגיונית מכך ונקודות אלה הרבה יותר משמעותיות לגבול ההחלטה מאשר הדאטה בהן פחות חידש משמעותית יותר חשוב לבדוק בהן בקבילת הסיווג הסופי.

5)




ניתן לראות מספר שינויים בגרפים כאשר הרעש הוא 0.4. ראשית המודל הרעה פחות מדויק באופן כללי כפי שניתן לראות בgraf הראשון והשלישי, שנייה ככל שיש יותר לומדים מאחר והדעתה אינו מוגלי מושלם נוצרות יותר הפרדות בין הדגימות וגבול ההחלטה תהיה יותר ויותר מפוזר ומבולגן. שלישי בgraf הרביעי ניתן לראות שמשקל הדגימות מפוזר מאוד ולא בהכרח קרוב לגבול ההחלטה כנראה בגלל הרעש שהוא הרבה רבת משקל גבוהה מהנדרש.

ניתן לראות בבירור בgraf הראשון את הביאס וארינס טרייד אוף, ככל שיש יותר לומדים השגיאה על דатаה האימון יורדת, ככל שהbias יורד אך השגיאה על דатаה הטסט עולה- ככל שהbias עולה. דבר המיציג באופן מדויק את הטרייד אוף ואת הסכנה באובר פיטינג.

Cross Validation:

(2) תחילת ניסיתי למבודט בטווח של 0 עד 3 בקפיצות די גדולות וקיבלי תיגרפים שלא כל כך הראו את המגמה כמו שצרי בנוספ' למבדות אופטימליות מאד קטנות ולכן החלטתי ללקת על טווח למבדות בקפיצות מאד קטנות וליצג אותן בגרף בסולם לוגריטמי כדי להציג את ההבדל הקפיצות ולהראות את המגמה הנדרשת.



```
Best Ridge λ = 0.06481, Test Error = 3423.47
Best Lasso λ = 0.00102, Test Error = 7305.27
Least Squares Test Error = 7991.27
```

ניתן לראות מספר דברים מהגרפים והතוצאות: ראשית בשני מודלי הרגולרייזציה קיבלנו למבדה אופטימלי מאד קטן שהביא לשיפור בשגיאה לעומת גרסיה לא רגולרייזציה. שנית ניתן לראות שלดาטה המסויים שלנו רידג' הביא לתוצאה יותר טובה כנראה בגל שיש יותר פיצרים בעלי קישוריות לנארית לתוצאות (מאופן פועלות רידג'). בנוסף נשים לב למוגמתויות בטוויח הלמבדה של שני מודלי הרגולרייזציה, בשנייהם בתחלת העליה בערכיו הלמבדה הקטנים ניכר שיפור בשגיאה בדאטה הואלידציה ככלומר המודל יכול השתרף אך החל מנקודות המינימום ניכרה עלייה כלומר המודל כבר לא משתפר ומתחל לחייב פחות טוב- זה מתכתב בדיקוק עם החומר הנלמד בכיתה וمعد על מציאת הלמבדה האופטימלי למודל. בנוסף נראה שבדאטה האימון ניכרת עלייה תמידית בשגיאה שזה הגיוני מאחר וכל שמשקל הרגולרייזציה עולה הביאו גם הוא ואיתו השגיאה על סט האימון. נשים לב שבמודול הלאסו החל מלמדה מסוים השגיאה מתיזכט שזה הגיוני מאחר ומודל זה מאפס פיצרים ולכן יכול לגרום להתייצבות השגיאה החל מממשקל מסוים.