

# Theoretical part:

## 1.1: Regularization

a)  $X \in \mathbb{R}^{m \times d}$ ,  $y \in \mathbb{R}^m$   $X^T X = P \in \mathbb{R}^{d \times d}$

$\hat{w} = \text{LS solution}$ ,  $\hat{w}_\lambda = \text{ridge solution } \lambda \geq 0$

$$y = Xw + \epsilon, \epsilon \sim N(0, \sigma^2), \text{Bias}(\hat{w}) = 0$$

$$\mathbb{E}(w) = \mathbb{E}(w + (X^T X)^{-1} X^T \epsilon) = w + (X^T X)^{-1} X^T \mathbb{E}(\epsilon) = w$$

$$\hat{w}_\lambda = (X^T X + \lambda I_d)^{-1} (X^T y) \quad : \text{§3}$$

∴ Ridge solution is a more robust solution than LS due to regularization

$$\hat{w}_\lambda = (X^T X + \lambda I_d)^{-1} X^T y = \arg \min \|Xw - y\|^2 + \lambda \|w\|^2$$

For numerical stability problems in numerical computation we use LS if possible

$$\hat{w} = (X^T X)^{-1} X^T y$$

$$\downarrow \quad I_d$$

$$(X^T X + \lambda I_d)^{-1} (X^T X) \cdot (X^T X)^{-1} X^T y = (X^T X + \lambda I_d)^{-1} X^T y$$

ב) מינימיזציה של פונקציית האפסה

b)  $\hat{w}_x = (x^T x + \lambda I_d)^{-1} (x^T x) \cdot \hat{w}$

$$E(\hat{w}_x) = E[(x^T x + \lambda I_d)^{-1} (x^T x) \cdot \hat{w}]$$

$$\text{לפניהם } E(\hat{w}) = w$$

$$= (x^T x + \lambda I_d)^{-1} (x^T x) \cdot E(\hat{w}) = \boxed{(x^T x + \lambda I_d)^{-1} x^T x \cdot w}$$

רעיון גאומטרי מינימיזציה של פונקציית האפסה

השכלה מינימלית כהוכחה,  $x^T x$  מינימלית כהוכחה $w$  מינימלית כהוכחה,  $E(\hat{w}_x) \neq w$ , bias ≠ 0

$\lambda > 0$  פ.к.  $E(\hat{w}_x) \neq w$ , bias ≠ 0 ⇒ גיאומטריה

c)  $\text{Var}(\hat{w}_x) = \text{Var}(A_x \hat{w}) = A_x \cdot \text{Var}(\hat{w}) A_x^T$

$$\stackrel{\text{השכלה}}{=} A_x \underbrace{\sigma^2}_{\text{סטיות}} (x^T x)^{-1} A_x^T \stackrel{\text{השכלה}}{=} \sigma^2 A_x (x^T x)^{-1} A_x^T$$

d)  $\text{MSE}(\hat{w}_x) = E[||\hat{w}_x - w||^2] = E[(\hat{w}_x - E(\hat{w}_x))^T (\hat{w}_x - E(\hat{w}_x))]$

$$= ||E(\hat{w}_x - w)||^2 + E(||\hat{w}_x - E(\hat{w}_x)||^2)$$

bias

Var

$$\text{bias}^2(x) = \left( E(\hat{w}_x) - E(\hat{w}) \right)^2 = \left( (A_x - I) w \right)^2$$

$$\text{Var}(x) = \sigma^2 \text{Tr}\left(A_x (x^T x)^{-1} A_x^T\right) =$$

מינימום  
הכפלה  
בנורמליזציה  
המינימום

↙

$$\boxed{\text{MSE}(\hat{x}_\lambda) = \| (A_x - I) w \|^2 + \sigma^2 \text{Tr}\left(A_x (x^T x)^{-1} A_x^T\right)}$$



e)

אם  $\lambda = 0$  אז מינימום שגיאה מינימום נורמליזציה  
 אם  $\lambda$  לא מוגדר אז שגיאה מינימום נורמליזציה  
 פונקציית שגיאה מינימום נורמליזציה  
 קיימת שגיאה מינימום נורמליזציה  
 הינה שגיאה מינימום נורמליזציה  
 שגיאה מינימום נורמליזציה

1.2-

a)  $X \in \mathbb{R}^{m \times d}$ ,  $y \in \mathbb{R}^m$ ,  $L \in \mathbb{R}^{K \times d}$ ,  $X^T X - \lambda I_d$  מינימום

$\underset{w \in \mathbb{R}^d}{\operatorname{argmin}} (||Xw - y||^2 + ||Lw||^2)$  סולו כרוכסן גודל רדיאן

פונקציית רתק לא-טראגייה של גודל רדיאן רתק ריבשי

Ridges פונקציית גודל רדיאן רתק ריבשי

$$||Xw - y||^2 + ||Lw||^2 = (Xw - y)^T (Xw - y) + (Lw)^T (Lw)$$

$$= w^T X^T X w - 2y^T X w + y^T y + w^T L^T L w$$

$$= w^T (X^T X + L^T L) w - 2y^T X w + y^T y$$

$$= w^T (X^T X + L^T L) w - 2y^T X w + y^T y$$

$$w^T A w = 2A w, b^T w = b \quad : w \cdot \text{deg} \rightarrow \text{deg}, \text{deg}$$

$$\nabla = 2(X^T X + L^T L)w - 2X^T y$$

: פונקציית גודל רדיאן רתק א-סולו

$$\cancel{\nabla} (X^T X + L^T L) w = \cancel{\nabla} X^T y$$

$$W_L^{T,K} = \boxed{w = (X^T X + L^T L)^{-1} X^T y}$$



b) מינימיזציה של פונקציית כפיפה מוגדרת כ  $\|x\|^2$ . נסמן  $x^T x = \|x\|^2$ . מינימיזציה זו מוגדרת כ  $x^T x + L^T L$ , כלומר  $L^T L$  מוגדרת כ מטריצה סימטרית חיובית (PSD). מינימיזציה כזו מוגדרת כ מינימום קומפקטי.

c)  $x = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$ ,  $y = \begin{bmatrix} 5 \\ 6 \end{bmatrix} \Rightarrow x^T = \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix}$

$$LS \rightarrow \hat{w} = (x^T x)^{-1} x^T y$$

i)  $\hat{w} = \left( \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \right)^{-1} \cdot \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix} \cdot \begin{bmatrix} 5 \\ 6 \end{bmatrix}$

$$= \begin{bmatrix} 10 & 14 \\ 14 & 20 \end{bmatrix}^{-1} \cdot \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 5 \\ 6 \end{bmatrix} = \frac{1}{200-196} \begin{bmatrix} 20 & -14 \\ -14 & 10 \end{bmatrix} \cdot \underbrace{\begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 5 \\ 6 \end{bmatrix}}_{x^T y}$$

$$= \frac{1}{4} \begin{bmatrix} 20 & -14 \\ -14 & 10 \end{bmatrix} \cdot \begin{bmatrix} 23 \\ 34 \end{bmatrix} = \begin{bmatrix} 5 & -\frac{14}{4} \\ -\frac{14}{4} & 2.5 \end{bmatrix} \begin{bmatrix} 23 \\ 34 \end{bmatrix} = \boxed{\begin{bmatrix} -4 \\ 4.5 \end{bmatrix}}$$

ii)  $\underline{\lambda=1}$   
 $\hat{w}_{\text{Ridge}} = (x^T x + \lambda I_2)^{-1} x^T y$

מינימיזציה רגוליזציה Ridge:

$$x^T y = \begin{bmatrix} 23 \\ 34 \end{bmatrix}$$

$$x^T x = \begin{bmatrix} 10 & 14 \\ 14 & 20 \end{bmatrix}$$

1 Ridge  $\hat{w}_x = \left( \begin{bmatrix} 10 & 14 \\ 14 & 20 \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \right)^{-1} \begin{bmatrix} 23 \\ 34 \end{bmatrix}$

$$= \begin{bmatrix} 11 & 14 \\ 14 & 21 \end{bmatrix}^{-1} \begin{bmatrix} 23 \\ 34 \end{bmatrix} = \frac{1}{21 \cdot 11 - 196} \begin{bmatrix} 21 & -14 \\ -14 & 11 \end{bmatrix} \begin{bmatrix} 23 \\ 34 \end{bmatrix}$$

$$= \begin{bmatrix} \frac{21}{35} & -\frac{14}{35} \\ -\frac{14}{35} & \frac{11}{35} \end{bmatrix} \begin{bmatrix} 23 \\ 34 \end{bmatrix} = \boxed{\begin{bmatrix} 0.2 \\ 1.48 \end{bmatrix}}$$

iii)  $\hat{w}^{Tik} = (x^T x + L^T L)^{-1} x^T y$   $L = \begin{bmatrix} 0 & 0 \\ 0 & 2 \end{bmatrix}$   
p. 765 f. 5. Auflage

$L^T L = \begin{bmatrix} 0 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 0 & 0 \\ 0 & 2 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 4 \end{bmatrix}$ ,  $x^T x = \begin{bmatrix} 10 & 14 \\ 14 & 20 \end{bmatrix}$ ,  $x^T y = \begin{bmatrix} 23 \\ 34 \end{bmatrix}$

$$L^T L = \begin{bmatrix} 0 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 0 & 0 \\ 0 & 2 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 4 \end{bmatrix}$$

$$\hat{w}^{Tik} = \left( \begin{bmatrix} 10 & 14 \\ 14 & 20 \end{bmatrix} + \begin{bmatrix} 0 & 0 \\ 0 & 4 \end{bmatrix} \right)^{-1} \begin{bmatrix} 23 \\ 34 \end{bmatrix} = \left( \begin{bmatrix} 10 & 14 \\ 14 & 24 \end{bmatrix} \right)^{-1} \begin{bmatrix} 23 \\ 34 \end{bmatrix}$$

$$= \frac{1}{240 - 196} \begin{bmatrix} 24 & -14 \\ -14 & 10 \end{bmatrix} \begin{bmatrix} 23 \\ 34 \end{bmatrix} = \begin{bmatrix} \frac{24}{44} & -\frac{14}{44} \\ -\frac{14}{44} & \frac{10}{44} \end{bmatrix} \begin{bmatrix} 23 \\ 34 \end{bmatrix} = \boxed{\begin{bmatrix} 1.72 \\ 0.41 \end{bmatrix}}$$

$$i) \|\vec{w}\| = \sqrt{4^2 + 4.5^2} = 6.02$$

$$\|\vec{w}_{\lambda=1}^{\text{Ridge}}\| = \sqrt{0.2^2 + 1.48^2} = 1.493$$

$$\|\vec{w}^{\text{Tikh}}\| = \sqrt{1.72^2 + 0.41^2} = 1.765$$

$$\boxed{\|\vec{w}_{\lambda=1}^{\text{Ridge}}\| < \|\vec{w}^{\text{Tikh}}\| < \|\vec{w}\|}$$

LS פסּוֹלְקָה (במונטג'ו) מוביל לערך נקי אחד.

ולא נזריק פסּוֹלְקָה אם הרצף יתאפשר. אך יפה גורר כטוריים

ולא נזריק פסּוֹלְקָה אם הרצף לא יוכל להיות מושג.

הזרקה לה היא הנאה כי רצף נקי לא יתאפשר.

ולא, גורא קורר רצף נקי אם דוגמאות מוגבלות.

בזאת בפערן גזרה פסּוֹלְקָה מילוי ציון.

בזיהוי אוסף גפסּוֹלְקָה מילוי ציון.

כלומר,

ככ. ספּריטני דומם פסּוֹלְקָה (זיהוי מילוי ציון).

ובזאת מילוי ציון מילוי ציון.

ולא, מילוי ציון מילוי ציון.


פסּוֹלְקָה מילוי ציון מילוי ציון.

פסּוֹלְקָה מילוי ציון מילוי ציון.

ולא, מילוי ציון מילוי ציון.

## 1.2 - PCA -

$$x_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad x_2 = \begin{bmatrix} -1 \\ 1 \end{bmatrix}, \quad x_3 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$




a)  $\bar{x} = \frac{1}{3} \sum_{i=1}^3 x_i = \frac{1}{3} \begin{pmatrix} 1-1+1 \\ 2+1+1 \end{pmatrix} = \begin{pmatrix} 1 \\ 4 \end{pmatrix} = \boxed{\begin{pmatrix} \frac{1}{3} \\ \frac{4}{3} \end{pmatrix}}$

$$z_1 = \begin{pmatrix} 1 \\ 2 \end{pmatrix} - \begin{pmatrix} \frac{1}{3} \\ \frac{4}{3} \end{pmatrix} = \begin{pmatrix} \frac{2}{3} \\ \frac{2}{3} \end{pmatrix}$$

$$z_2 = \begin{pmatrix} -1 \\ 1 \end{pmatrix} - \begin{pmatrix} \frac{1}{3} \\ \frac{4}{3} \end{pmatrix} = \begin{pmatrix} -\frac{4}{3} \\ -\frac{1}{3} \end{pmatrix}$$


$$z_3 = \begin{pmatrix} 1 \\ 1 \end{pmatrix} - \begin{pmatrix} \frac{1}{3} \\ \frac{4}{3} \end{pmatrix} = \begin{pmatrix} \frac{2}{3} \\ -\frac{1}{3} \end{pmatrix}$$



b)

$$\Sigma = \begin{bmatrix} 8 & 2 \\ 2 & 9 \end{bmatrix} \Rightarrow \lambda = 0.956 \quad \alpha = \begin{pmatrix} -0.9571 \\ -0.2898 \end{pmatrix}$$

(Cores röd pion)



c)

$$V^+ z_1 = -0.83$$

$$V^+ z_2 = 1.32$$

$$V^+ z_3 = -0.48$$

d)


$$\check{v}(v^T z_1) = \begin{pmatrix} -0.9571 \\ -0.2898 \end{pmatrix} \cdot 0.83 = \begin{pmatrix} 0.796 \\ 0.241 \end{pmatrix}$$

$$\check{v}(v^T z_2) = \begin{pmatrix} -0.9571 \\ -0.2898 \end{pmatrix} \cdot 1.32 = \begin{pmatrix} -1.314 \\ -0.394 \end{pmatrix}$$

$$\check{v}(v^T z_3) = \begin{pmatrix} -0.9571 \\ -0.2898 \end{pmatrix} \cdot 0.48 = \begin{pmatrix} 0.518 \\ 0.157 \end{pmatrix}$$

✓

e)



$$x_1^R = \begin{pmatrix} 1.12 \\ 1.574 \end{pmatrix}$$

$$x_2^R = \begin{pmatrix} -0.98 \\ 0.93 \end{pmatrix}$$

$$x_3^R = \begin{pmatrix} 0.85 \\ 1.49 \end{pmatrix}$$

$$V = \begin{pmatrix} \frac{1}{3} \\ \frac{3}{4} \end{pmatrix} + \begin{pmatrix} -0.9571 \\ -0.2898 \end{pmatrix} \alpha$$

$$2) \sum_i = x_i - \bar{x} , w^T w \rightarrow \delta_{123}$$

a)

$$\sum_{i=1}^m \|x_i - \bar{x} - w^T w(x_i - \bar{x})\|^2 = \sum_{i=1}^m \|z_i\|^2 - z_i^T w^T w z_i : \text{Eq 3}$$

$$z_i = x_i - \bar{x}$$

$$\sum_{i=1}^m \|x_i - \bar{x} - w^T w(x_i - \bar{x})\|^2 = \sum_{i=1}^m \|z_i - w^T w z_i\|^2$$

$$= \sum_{i=1}^m \|z_i\|^2 - 2 z_i^T w^T w z_i + \|w^T w z_i\|^2$$

↗  
non 0  
δδ

$$= \sum_{i=1}^m \|z_i\|^2 - 2 z_i^T w^T w z_i + z_i^T w^T w w^T w z_i$$

↗  
non 0  
δδ

$$\underline{\underline{w^T w}} \rightarrow \sum_{i=1}^m \|z_i\|^2 - 2 z_i^T w^T w z_i + z_i^T w^T w z_i$$

$w^T w w^T w = w^T w$

$$= \sum_{i=1}^m \|z_i\|^2 - z_i^T w^T w z_i$$



$$b) \sum_{i=1}^m z_i^T w^T w z_i = m \cdot \text{Tr}(w \Sigma w^T)$$

dfb

$a \in \mathbb{R}$

$$\text{Tr}(a) = a$$

$$\sum_{i=1}^m z_i^T w^T w z_i = \sum_{i=1}^m \text{Tr}(z_i^T w^T w z_i)$$

→ dfb

$$\text{Tr}(AB) = \text{Tr}(BA)$$

$$\Rightarrow \sum_{i=1}^m \text{Tr}(w z_i z_i^T w^T) \stackrel{\text{dfb}}{=} \text{Tr}\left(w \left(\sum_{i=1}^m z_i z_i^T\right) w^T\right)$$

$$\sum = \frac{1}{m} \sum_{i=1}^m (x_i - \bar{x})(x_i - \bar{x})^T = \frac{1}{m} \sum_{i=1}^m z_i z_i^T$$

→ dfb n = m

$$\Rightarrow \text{Tr}(w (m \cdot \sum) w^T) = m \cdot \text{Tr}(w \Sigma w^T)$$



$$c) w = \begin{bmatrix} v_1^T \\ \vdots \\ v_k^T \end{bmatrix} \quad \text{Tr}(w \Sigma w^T) = \sum_{j=1}^k v_j^T \Sigma v_j \quad : \text{dfb}$$

$$\text{Tr}(w \Sigma w^T) = \text{Tr}\left(\begin{bmatrix} v_1^T \\ \vdots \\ v_k^T \end{bmatrix} \cdot \sum \cdot \begin{bmatrix} v_1 & \dots & v_k \end{bmatrix}\right)$$

→ dfb  
Trace

$$= \text{Tr}\left(\begin{bmatrix} v_1^T \cdot \sum \cdot v_1 & \dots & v_n^T \cdot \sum \cdot v_n \\ \vdots & \ddots & \vdots \\ v_k^T \cdot \sum \cdot v_k & \dots & v_1^T \cdot \sum \cdot v_1 \end{bmatrix}\right) = \sum_{j=1}^k v_j^T \Sigma v_j$$



ד)  $\sum_{i=1}^m \|x_i - \bar{x} - w^\top w(x_i - \bar{x})\|^2 = \sum_{i=1}^m \|z_i\|^2 - z_i^\top w^\top w z_i$

$$= \underbrace{\sum_{i=1}^m \|z_i\|^2}_{\text{sum of squared distances}} - \underbrace{\sum_{i=1}^m z_i^\top w^\top w z_i}_{\text{sum of weighted distances}}$$

כגון בדרכו נקבע שפער השגיאה מוגדר כ

$$\sum_{i=1}^m z_i^\top w^\top w z_i$$

ובכך  $w = \begin{bmatrix} v_1^\top \\ \vdots \\ v_k^\top \end{bmatrix}$  פירושו של דבר הוא ש

$$\sum_{i=1}^m z_i^\top w^\top w z_i = m \cdot \text{Tr}(w w^\top) = m \cdot \sum_{j=1}^k v_j^\top v_j$$

לכן מינימיזציית שפער השגיאה מוגדרת כ



המשמעותה היא

3)

$$x : \mathcal{S} \rightarrow \mathbb{R}^d \quad \sum \in \mathbb{R}^{d \times d} \quad V \in \mathbb{R}^d, \quad \|\sum\|_2 = 1$$

$$\mathbb{E}[x] = 0$$

ונוכיח כי  $y_1$  בPCA הוא מינימום  $\lambda_1$  ו-

בנוסף PCA הוא מינימום כפוי因为他 הוא מינימום  $\lambda_1$ .

$y_1$  מינימום כפוי והוא מינימום  $\lambda_1$ .

$$V_1^T V_1 = \lambda_1 \quad \text{PCA} \quad \text{Normalization} \quad \text{Goal}$$

$$\|V\|=1 \quad \text{unitary } V \quad \text{for } \text{orthogonal } \text{matrix } \text{of } \text{size } n$$

$$\text{Var}(\langle V, X \rangle) \leq V_1^T V_1 = \lambda_1$$

$$\text{Var}(\langle V, X \rangle) = E((V^T X)^2) = V^T E[X X^T] V = V^T V = \lambda_v$$

בנוסף לORTHOGONALITY, PCA מגדיר ממד אחד בלבד.

$$\text{Var}(\langle V, X \rangle) = \lambda_v \leq \lambda_1 = V_1^T V_1$$

בנוסף PCA מגדיר ממד אחד בלבד.



# 1.3 - clustering:

a) True

প্রতি ক্লাসের মধ্যে প্রতিটি ক্লাসের মধ্যে দূরত্ব অনেক কম।  
 $C_{final}$  এর মধ্যে প্রতিটি ক্লাসের মধ্যে দূরত্ব অনেক বেশি।

b) False

ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক কম।  
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক বেশি।  
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক কম।

c) True

ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক কম।  
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক বেশি।  
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক কম।  
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক বেশি।

d) True


ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক কম।  
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক বেশি।  
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক কম।  
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক বেশি।

## Practical part Answers:

### **Boosting:**

**0 noise:**


**1)**



כפי שניתן לראות התוצאות תואמות את הציפיות- ככל שמספר הלומדים עולה שגיאת הקלאסיפיקציה יורדת, בערכיהם הקטנים יחסית השגיאה מאוד תנומתית אף במספר מסוים באחור ה-25 לומדים השגיאה מתיצבת ומשתפרת באופן איטי מאד כפונקציה של הגדלת מספר הלומדים. מוגמה זאת הגונית מאחר שמספר לומדים מסוים התוצאות כבר ד' מתמחזרות ולהלומדים חוזרים על עצם ולכך מד"קם ברמה מאוד קטנה את השגיאה.


**2)**

AdaBoost Decision Boundaries at Different Iterations




ניתן לראות שבמספר לומדים נמוך גבול החלטה היה כל הדאטה ולכן ניתן שגיאת גדולה ולא מדויקת אף כי מספר הלומדים עולה הדאטה ומונע תוצאות איקוטיות יותר. בנוסף ניתן לראות שהגבול עצמו יהיה יותר ויותר מעגלי בהתאם למינימום מרובע זהה הגינוי מאוחר ויש למודל יותר גדמי החלטה לעבוד לפיהם כלומר יותר מלבדים לסמן על גוף ההחלטה וכן יכול לבדוק יותר ויתר את הגבול האמתי על הדאטה עצמו שנמצא בצורה מעגלית.

3)




4)



ניתן לראות בגרף הממושקל של נקודות על התפר של גבול ההחלטה היו משקלים יותר גדולים בהרבה מהנקודות הרחוקות מהגבול, זאת תוצאה הגינויית מאחר ונקודות אלה הרבה יותר משמעותיות לגבול ההחלטה מאשר הדאטה בהן פחות חדי משמעי ויתר חשוב לבדוק לדיק בהן בקבלת הסיווג הסופי.

5)




ניתן לראות מספר שינויים בגרפים כאשר הרעש הוא 0.4. ראשית המודל הרעה פחות מדויק באופן כללי כפי שניתן לראות בgraf הראשון והשלישי, שנייה ככל שיש יותר לומדים מאחר והדעתה איננו מוגלי מושלם נוצרות יותר הפרדות בין הדגימות וגבול ההחלטה תהיה יותר ויותר מפוזר ומבולגן. שלישי בgraf הרביעי ניתן לראות שמשקל הדגימות מפוזר מאוד ולא בהכרח קרוב לגבול ההחלטה כנראה בגלל הרעש שהוא הרבה רבת משקל גבוהה מהנדרש.

ניתן לראות בבירור בgraf הראשון את הביאס והרינס טרייד אוף, ככל שיש יותר לומדים השגיאה על דатаה האימון יורדת, ככל שהbias יורד אך השגיאה על דатаה הטסט עולה- ככל שהרינס עולה. דבר המיצג באופן מדויק את הטרייד אוף ואת הסכנה באובר פיטינג.

## Cross Validation:

2) תחילה ניסיתי למבודט בטווח של 0 עד 3 בקפיצות די גדולות וקיבلت הגרפים שלא כל כך הראו את המגמה כמו שצריך בנוספף למלבדות אופטימליות מאוד קטנות ולכן החלטתי ללקת על טווח למלבדות בקפיצות מאוד קטנות וליצג אותן בגרף בסולם לוגריתמי כדי להציג את ההבדל הקפיצות ולהראות את המגמה הנדרשת.



```
Best Ridge λ = 0.0233, Test Error = 3253.3949
Best Lasso λ = 0.0648, Test Error = 3515.1410
Least Squares Test Error = 3612.2211
```

ניתן לראות מספר דברים מהגרפים והතוצאות: ראשית בשני מודלי הרגולרייזציה קיבלנו למלבדה אופטימלי מאוד קטן שהביא לשיפור של בין 2-10 אחוזים בשגיאה לעומת לוגרטייה לא רגולרייזציה. שנית ניתן לראות שלדעתה המסוימת שלנו רידג' הביא לתוצאה יותר טובה ונראה בגל שיש יותר פיצרים בעלי קשריות לנארית לתוצאות (מאופן פועלות רידג'). בנוסף נשים לב למוגמתויות בטווחי הלמבדה של שני מודלי הרגולרייזציה, בשנייהם בתחלת העליה בערכי הלמבדה הקטנים ניכר שיפור בשגיאה בDATA הואlidציה לומר המודל יכול השיפור אף החלה מנקודת המינימום ניכרה עלייה כלומר המודל כבר לא משתפר ומתחיל להיות פחות טוב. זה מתכתב בדיק עם החומר הנלמד בכיתה ומיד על מציאת הלמבדה האופטימלי למודל. בנוסף נראה שבDATA האימון ניכרת עלייה תמידית בשגיאה שזה הגיוני מאחר וככל שמשקל הרגולרייזציה עולה הביאו עלייה גם הוא ואיתו השגיאה על סט האימון. נשים לב שבמודל הלאסוטו החל מלמداد מסוימים השגיאה מת'יצבת שזה הגיוני מאחר ומודל זה מופיע פיצרים וכן יכול לגרום להתייצבות השגיאה החל משקל מסוימים.