

# Theoretical part:

## 1.1: Regularization

a)  $X \in \mathbb{R}^{m \times d}$ ,  $y \in \mathbb{R}^m$   $X^T X = P \in \mathbb{R}^{d \times d}$

$\hat{w} = \text{LS solution}$ ,  $\hat{w}_\lambda = \text{ridge solution } \lambda \geq 0$

$$y = Xw + \epsilon, \epsilon \sim N(0, \sigma^2), \text{Bias}(\hat{w}) = 0$$

$$\mathbb{E}(w) = \mathbb{E}(w + (X^T X)^{-1} X^T \epsilon) = w + (X^T X)^{-1} X^T \mathbb{E}(\epsilon) = w$$

$$\hat{w}_\lambda = (X^T X + \lambda I_d)^{-1} (X^T y) \quad : \text{§3}$$

∴ Ridge solution is a more robust solution than LS due to regularization

$$\hat{w}_\lambda = (X^T X + \lambda I_d)^{-1} X^T y = \arg \min \|Xw - y\|^2 + \lambda \|w\|^2$$

For numerical stability problems in numerical computation we use LS if possible

$$\hat{w} = (X^T X)^{-1} X^T y$$

$$\downarrow \quad I_d$$

$$(X^T X + \lambda I_d)^{-1} (X^T X) \cdot (X^T X)^{-1} X^T y = (X^T X + \lambda I_d)^{-1} X^T y$$



ב) מינימום א-טפס

b)  $\hat{w}_x = (x^T x + \lambda I_d)^{-1} (x^T x) \cdot \hat{w}$

↓

$$E(\hat{w}_x) = E[(x^T x + \lambda I_d)^{-1} (x^T x) \cdot \hat{w}]$$

| $x^T x + \lambda I_d = w$ 

$$= (x^T x + \lambda I_d)^{-1} (x^T x) \cdot E(\hat{w}) = \boxed{(x^T x + \lambda I_d)^{-1} x^T x \cdot w}$$

רעיון גאומטרי דראטיון בוגר מינימום סqr(הפרש)

השכלה כהוכחה רציפה,  $x^T x$  מוגדרת כפונקציית פיתוחw מוגדרת כפונקציית פיתוח, כוונת ה- $\hat{w}$  מינימלית

$\lambda > 0$  פlc  $E(\hat{w}_x) \neq w$ , bias  $\neq 0$   $\Rightarrow$  צניגר

a<sub>zero</sub>

minus

c)  $Var(\hat{w}_x) = Var(A_x \hat{w}) = A_x \cdot Var(\hat{w}) A_x^T$

$$\stackrel{\text{סימן}}{=} A_x \underbrace{\sigma^2}_{\text{disp}} (x^T x)^{-1} A_x^T \stackrel{\text{סימן}}{=} \sigma^2 A_x (x^T x)^{-1} A_x^T$$



כרטס

d)  $MSE(\hat{x}_x) = E[||\hat{w}_x - w||^2] = E[(\hat{w}_x - w)^T (\hat{w}_x - w)]$

$$= ||E(\hat{w}_x - w)||^2 + E(||\hat{w}_x - E(\hat{w}_x)||^2)$$

bias

Var

$$\text{bias}^2(x) = \left( E(\hat{w}_x) - E(\hat{w}) \right)^2 = \left( (A_x - I) w \right)^2$$

$$\text{Var}(x) = \sigma^2 \text{Tr}\left(A_x (x^T x)^{-1} A_x^T\right) =$$

מינימום  
הכפלה  
בנובע מכך

↙

$$\boxed{\text{MSE}(\hat{x}_\lambda) = \| (A_x - I) w \|^2 + \sigma^2 \text{Tr}\left(A_x (x^T x)^{-1} A_x^T\right)}$$



e)

אם  $\lambda = 0$  אז מינימום האטראקטיבי נתקיים ב-

אם  $\lambda > 0$  אז מינימום לא קיים וקיים מינימום כפלי.

במקרה של bias  $\lambda = 0$  מינימום מושג ב-

במקרה של variance מינימום מושג ב-

אנו מודדים bias ו-variance ב-

ridge regression כפונקציית כפלה מינימלית (lambda \* bias^2 + (1-lambda) \* var^2)

ולפונקציית כפלה מינימלית מושג מינימום ב-

1.2-

a)  $X \in \mathbb{R}^{m \times d}$ ,  $y \in \mathbb{R}^m$ ,  $L \in \mathbb{R}^{k \times d}$ ,  $X^T X - \lambda I_d$  דוגמא

$\underset{w \in \mathbb{R}^d}{\operatorname{argmin}} (||Xw - y||^2 + ||Lw||^2)$  סולו כרוכן יסוד ר' יסוד

פונקציית רקע לפונקציית האנרגיה ר' יסוד

Ridge function יסוד ר' יסוד

$$||Xw - y||^2 + ||Lw||^2 = (Xw - y)^T (Xw - y) + (Lw)^T (Lw)$$

$$= w^T X^T X w - 2y^T X w + y^T y + w^T L^T L w$$

$$= w^T (X^T X + L^T L) w - 2y^T X w + y^T y$$

$$= w^T (X^T X + L^T L) w - 2y^T X w + y^T y$$

$$w^T A w = 2Aw, b^T w = b \quad : w \cdot \text{deg} \text{ יישום, יסוד}$$

$$\nabla = 2(X^T X + L^T L)w - 2X^T y$$

: פונקציית אפסיון יסוד יסוד יסוד יסוד

$$\cancel{\nabla} (X^T X + L^T L)w = \cancel{\nabla} X^T y$$

$$W_L^{T,K} = \boxed{w = (X^T X + L^T L)^{-1} X^T y}$$



b)

הנורמליזציה מושגת באמצעות  $X^T X$

או  $X^T X + L^T L$  אם  $L$  מוגדר

כך שORTHOGONALITY מושגת באמצעות  $X^T X + L^T L$  ו- $y$  מושג

於是, זה מגדיר מטריצת כטבורה PSD

לפיה נסמן  $\hat{w}$  כפתרון למשוואת נורמליזציה  $X^T y = 1$

c)

$$X = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}, \quad y = \begin{bmatrix} 5 \\ 6 \end{bmatrix} \Rightarrow X^T = \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix}$$

$$\text{LS} \rightarrow \hat{w} = (X^T X)^{-1} X^T y$$

i)

$$\hat{w} = \left( \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \right)^{-1} \cdot \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix} \cdot \begin{bmatrix} 5 \\ 6 \end{bmatrix}$$

$$= \begin{bmatrix} 10 & 14 \\ 14 & 20 \end{bmatrix}^{-1} \cdot \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 5 \\ 6 \end{bmatrix} = \frac{1}{200-196} \begin{bmatrix} 20 & -14 \\ -14 & 10 \end{bmatrix} \cdot \underbrace{\begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 5 \\ 6 \end{bmatrix}}_{x^T y}$$

$$= \frac{1}{4} \begin{bmatrix} 20 & -14 \\ -14 & 10 \end{bmatrix} \cdot \begin{bmatrix} 23 \\ 34 \end{bmatrix} = \begin{bmatrix} 5 & -\frac{14}{4} \\ -\frac{14}{4} & 2.5 \end{bmatrix} \begin{bmatrix} 23 \\ 34 \end{bmatrix} = \boxed{\begin{bmatrix} -4 \\ 4.5 \end{bmatrix}}$$

ii)

$$\lambda = 1$$

$$\hat{w}_{\text{Ridge}} = (X^T X + \lambda I_2)^{-1} X^T y$$

ולא נזקם ב- $\lambda$

$$x^T y = \begin{bmatrix} 23 \\ 34 \end{bmatrix}$$

: נאנו רעננו סלו  $x^T x = \begin{bmatrix} 10 & 14 \\ 14 & 20 \end{bmatrix}$

$$\hat{w}_x^{\text{Ridge}} = \left( \begin{bmatrix} 10 & 14 \\ 14 & 20 \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \right)^{-1} \begin{bmatrix} 23 \\ 34 \end{bmatrix}$$

$$= \begin{bmatrix} 11 & 14 \\ 14 & 21 \end{bmatrix}^{-1} \begin{bmatrix} 23 \\ 34 \end{bmatrix} = \frac{1}{21 \cdot 11 - 14 \cdot 14} \begin{bmatrix} 21 & -14 \\ -14 & 11 \end{bmatrix} \begin{bmatrix} 23 \\ 34 \end{bmatrix}$$

$$= \begin{bmatrix} \frac{21}{35} & -\frac{14}{35} \\ -\frac{14}{35} & \frac{11}{35} \end{bmatrix} \begin{bmatrix} 23 \\ 34 \end{bmatrix} = \boxed{\begin{bmatrix} 0.2 \\ 1.48 \end{bmatrix}}$$

iii)  $\hat{w}^{Tik} = (x^T x + L^T L)^{-1} x^T y$   $L = \begin{bmatrix} 0 & 0 \\ 0 & 2 \end{bmatrix}$   
ר.ג.ה. ג.ר.ל.ר.ר.

: י.ת.ל.ו. י.כ.כ.ו. ד.נ.ד. ל.נ.כ.ר.ל.  
 $L^T = \begin{bmatrix} 0 & 0 \\ 0 & 2 \end{bmatrix}$ ,  $x^T x = \begin{bmatrix} 10 & 14 \\ 14 & 20 \end{bmatrix}$ ,  $x^T y = \begin{bmatrix} 23 \\ 34 \end{bmatrix}$

$$L^T L = \begin{bmatrix} 0 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 0 & 0 \\ 0 & 2 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 4 \end{bmatrix}$$

$$\hat{w}^{Tik} = \left( \begin{bmatrix} 10 & 14 \\ 14 & 20 \end{bmatrix} + \begin{bmatrix} 0 & 0 \\ 0 & 4 \end{bmatrix} \right)^{-1} \begin{bmatrix} 23 \\ 34 \end{bmatrix} = \left( \begin{bmatrix} 10 & 14 \\ 14 & 24 \end{bmatrix} \right)^{-1} \begin{bmatrix} 23 \\ 34 \end{bmatrix}$$

$$= \frac{1}{240 - 196} \begin{bmatrix} 24 & -14 \\ -14 & 10 \end{bmatrix} \begin{bmatrix} 23 \\ 34 \end{bmatrix} = \begin{bmatrix} \frac{24}{44} & -\frac{14}{44} \\ -\frac{14}{44} & \frac{10}{44} \end{bmatrix} \begin{bmatrix} 23 \\ 34 \end{bmatrix} = \boxed{\begin{bmatrix} 1.72 \\ 0.41 \end{bmatrix}}$$

$$i) \|\vec{w}\| = \sqrt{4^2 + 4.5^2} = 6.02$$

$$\|\vec{w}_{\lambda=1}^{\text{Ridge}}\| = \sqrt{0.2^2 + 1.48^2} = 1.493$$

$$\|\vec{w}^{\text{Tikh}}\| = \sqrt{1.72^2 + 0.41^2} = 1.765$$

$$\boxed{\|\vec{w}_{\lambda=1}^{\text{Ridge}}\| < \|\vec{w}^{\text{Tikh}}\| < \|\vec{w}\|}$$

לפיה כפיג'ויניג פוליך או הדראה כי תוצאות נקבעו לאט

ולא נזרה בפיה או רצף גורם גורם אחד יפהן כביר

דיזה לה ביר הדראה כי רצף נזקן נזקן ורוצח דיזה

כדי גורקערר טיקונוב רצף נזקן ופיג'ויניג

בז'ה בפיה גורקערר טיקונוב רצף נזקן כפיג'ויניג

בז'ה בפיה גורקערר טיקונוב רצף נזקן כפיג'ויניג

כדו וו

ככ. בפינט, דפסי הדראה כפיג'ויניג קראוניג

ברצף פיג'ויניג גורקערר טיקונוב רצף נזקן כפיג'ויניג


טיקונוב Ridge פיג'ויניג רצף נזקן כפיג'ויניג

וכן כפיג'ויניג Ridge פיג'ויניג רצף נזקן כפיג'ויניג

פיג'ויניג Ridge פיג'ויניג רצף נזקן כפיג'ויניג.

## 1.2 - PCA -

$$x_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad x_2 = \begin{bmatrix} -1 \\ 1 \end{bmatrix}, \quad x_3 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$




a)  $\bar{x} = \frac{1}{3} \sum_{i=1}^3 x_i = \frac{1}{3} \begin{pmatrix} 1-1+1 \\ 2+1+1 \end{pmatrix} = \begin{pmatrix} 1 \\ 4 \end{pmatrix} = \boxed{\begin{pmatrix} \frac{1}{3} \\ \frac{4}{3} \end{pmatrix}}$

$$z_1 = \begin{pmatrix} 1 \\ 2 \end{pmatrix} - \begin{pmatrix} \frac{1}{3} \\ \frac{4}{3} \end{pmatrix} = \begin{pmatrix} \frac{2}{3} \\ \frac{2}{3} \end{pmatrix}$$

$$z_2 = \begin{pmatrix} -1 \\ 1 \end{pmatrix} - \begin{pmatrix} \frac{1}{3} \\ \frac{4}{3} \end{pmatrix} = \begin{pmatrix} -\frac{4}{3} \\ -\frac{1}{3} \end{pmatrix}$$


$$z_3 = \begin{pmatrix} 1 \\ 1 \end{pmatrix} - \begin{pmatrix} \frac{1}{3} \\ \frac{4}{3} \end{pmatrix} = \begin{pmatrix} \frac{2}{3} \\ -\frac{1}{3} \end{pmatrix}$$



b)

$$\Sigma = \begin{bmatrix} 8 & 2 \\ 2 & 9 \end{bmatrix} \Rightarrow \lambda = 0.956 \quad \alpha = \begin{pmatrix} -0.9571 \\ -0.2898 \end{pmatrix}$$

(Cores röd pion)



c)

$$V^+ z_1 = -0.83$$

$$V^+ z_2 = 1.32$$

$$V^+ z_3 = -0.48$$

d)


$$\check{v}(v^T z_1) = \begin{pmatrix} -0.9571 \\ -0.2898 \end{pmatrix} \cdot 0.83 = \begin{pmatrix} 0.796 \\ 0.241 \end{pmatrix}$$

$$\check{v}(v^T z_2) = \begin{pmatrix} -0.9571 \\ -0.2898 \end{pmatrix} \cdot 1.32 = \begin{pmatrix} -1.314 \\ -0.394 \end{pmatrix}$$

$$\check{v}(v^T z_3) = \begin{pmatrix} -0.9571 \\ -0.2898 \end{pmatrix} \cdot 0.48 = \begin{pmatrix} 0.518 \\ 0.157 \end{pmatrix}$$

✓

e)



$$x_1^R = \begin{pmatrix} 1.12 \\ 1.574 \end{pmatrix}$$

$$x_2^R = \begin{pmatrix} -0.98 \\ 0.93 \end{pmatrix}$$

$$x_3^R = \begin{pmatrix} 0.85 \\ 1.49 \end{pmatrix}$$

$$V = \begin{pmatrix} \frac{1}{3} \\ \frac{3}{4} \end{pmatrix} + \begin{pmatrix} -0.9571 \\ -0.2898 \end{pmatrix} \alpha$$

$$2) \sum_i = x_i - \bar{x} , w^T w \rightarrow \delta_{123}$$

a)

$$\sum_{i=1}^m \|x_i - \bar{x} - w^T w(x_i - \bar{x})\|^2 = \sum_{i=1}^m \|z_i\|^2 - z_i^T w^T w z_i : \text{Eq 3}$$

$$z_i = x_i - \bar{x}$$

$$\sum_{i=1}^m \|x_i - \bar{x} - w^T w(x_i - \bar{x})\|^2 = \sum_{i=1}^m \|z_i - w^T w z_i\|^2$$

$$= \sum_{i=1}^m \|z_i\|^2 - 2 z_i^T w^T w z_i + \|w^T w z_i\|^2$$

↗  
non 0  
δδ

$$= \sum_{i=1}^m \|z_i\|^2 - 2 z_i^T w^T w z_i + z_i^T w^T w w^T w z_i$$

↗  
non 0  
δδ

$$\underline{\underline{w^T w}} \rightarrow \sum_{i=1}^m \|z_i\|^2 - 2 z_i^T w^T w z_i + z_i^T w^T w z_i$$

$w^T w w^T w = w^T w$

$$= \sum_{i=1}^m \|z_i\|^2 - z_i^T w^T w z_i$$



$$b) \sum_{i=1}^m z_i^T w^T w z_i = m \cdot \text{Tr}(w \Sigma w^T)$$

dfb

$a \in \mathbb{R}$

$$\text{Tr}(a) = a$$

$$\sum_{i=1}^m z_i^T w^T w z_i = \sum_{i=1}^m \text{Tr}(z_i^T w^T w z_i)$$

dfb

$$\text{Tr}(AB) = \text{Tr}(BA)$$

$$\Rightarrow \sum_{i=1}^m \text{Tr}(w z_i z_i^T w^T) \stackrel{\text{dfb}}{=} \text{Tr}\left(w \left(\sum_{i=1}^m z_i z_i^T\right) w^T\right)$$

$$\sum = \frac{1}{m} \sum_{i=1}^m (x_i - \bar{x})(x_i - \bar{x})^T = \frac{1}{m} \sum_{i=1}^m z_i z_i^T$$

dfb no m

$$\Rightarrow \text{Tr}(w (m \cdot \sum) w^T) \stackrel{\text{dfb}}{=} m \cdot \text{Tr}(w \Sigma w^T)$$



$$c) w = \begin{bmatrix} v_1^T \\ \vdots \\ v_k^T \end{bmatrix} \quad \text{Tr}(w \Sigma w^T) = \sum_{j=1}^k v_j^T \Sigma v_j$$

dfb

$$\text{Tr}(w \Sigma w^T) = \text{Tr}\left(\begin{bmatrix} v_1^T \\ \vdots \\ v_k^T \end{bmatrix} \cdot \sum \cdot \begin{bmatrix} v_1 & \dots & v_k \end{bmatrix}\right)$$

dfb  
Trace

$$= \text{Tr}\left(\begin{bmatrix} v_1^T \cdot \sum \cdot v_1 & \dots & v_n^T \cdot \sum \cdot v_n \\ \vdots & \ddots & \vdots \\ v_k^T \cdot \sum \cdot v_k & \dots & v_1^T \cdot \sum \cdot v_1 \end{bmatrix}\right) \stackrel{\text{dfb}}{=} \sum_{j=1}^k v_j^T \Sigma v_j$$



ד)  $\sum_{i=1}^m \|x_i - \bar{x} - w^\top w(x_i - \bar{x})\|^2 = \sum_{i=1}^m \|z_i\|^2 - z_i^\top w^\top w z_i$

$$= \underbrace{\sum_{i=1}^m \|z_i\|^2}_{\text{sum of squared distances}} - \underbrace{\sum_{i=1}^m z_i^\top w^\top w z_i}_{\text{sum of weighted distances}}$$

כגון בדרכו נקבע שפער השגיאה מוגדר כ

$$\sum_{i=1}^m z_i^\top w^\top w z_i$$

ובכך  $w = \begin{bmatrix} v_1^\top \\ \vdots \\ v_k^\top \end{bmatrix}$  פירושו של דבר הוא ש

$$\sum_{i=1}^m z_i^\top w^\top w z_i = m \cdot \text{Tr}(w w^\top) = m \cdot \sum_{j=1}^k v_j^\top v_j$$

לכן מינימיזציית שפער השגיאה מוגדרת כ



המשמעותה היא

3)

$$x: \mathcal{S} \rightarrow \mathbb{R}^d \quad \sum \in \mathbb{R}^{d \times d} \quad V \in \mathbb{R}^d, \quad \|\sum\|_2 = 1$$

$$\mathbb{E}[x] = 0$$

ונוכיח כי  $y_1$ PCA הוא מינימום של  $\lambda_1$  (אנו)

בנוסף PCA הוא פונקציית כפיפה וולנטית, כלומר  $y_1$ PCA מוגדר

$y_1$ PCA מוגדר כפיפה וולנטית, כלומר  $y_1$ PCA מוגדר

$$V_1^T V_1 = \lambda_1 \quad \text{PCA} \quad \text{Normalization} \quad \text{Goal}$$

$$\|V\|=1 \quad \text{unitary } V \quad \text{for } \text{orthogonal } \text{matrix} \quad \text{unitary } V$$

$$\text{Var}(\langle V, X \rangle) \leq V_1^T V_1 = \lambda_1$$

$$\text{Var}(\langle V, X \rangle) = E((V^T X)^2) = V^T E[X X^T] V = V^T V = \lambda_v$$

בבז' פ' PCA נבדק אם הערך המרבי מוגדר נכון

$$\text{Var}(\langle V, X \rangle) = \lambda_v \leq \lambda_1 = V_1^T V_1$$

בבז' PCA נבדק אם הערך המרבי מוגדר נכון



# 1.3 - clustering:

a) True

প্রতি ক্লাসের মধ্যে প্রতিটি ক্লাসের মধ্যে দূরত্ব অনেক কম।  
 $C_{final}$  এর মধ্যে প্রতিটি ক্লাসের মধ্যে দূরত্ব অনেক বেশি।

b) False

ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক কম।  
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক বেশি।  
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক কম।

c) True

ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক কম।  
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক বেশি।  
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক কম।  
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক বেশি।

d) True

ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক কম।  
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক বেশি।  
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক কম।  
ক্লাসের মধ্যে প্রতিটি পয়সনের মধ্যে দূরত্ব অনেক বেশি।